LaktaFeed-Risk: Süt Sığırcılığında İnek-Gün Düzeyinde Sağlık Riski ve Besleme İhtiyacı Tahmini için Makine Öğrenmesi Altyapısı

Artun Kara
Kocaeli Üniversitesi
Kocaeli, Türkiye
artunankara@gmail.com

***Abstract*—Bu çalışma, süt sığırcılığında inek-gün düzeyinde yüksek enerji açığı riskini tahmin etmek için geliştirilen LaktaFeed-Risk makine öğrenmesi altyapısını ve deneysel sonuçlarını sunmaktadır. PostgreSQL tabanlı veri hattı, gözlenen ham MmCows kayıtlarını değiştirmeden korumakta; eksik alanları proxy olarak tamamlanan 240 satırlık omurgayı ve normalize veri katmanlarından geçirilen 21 600 satırlık bağımsız longitudinal sentetik kohortu tek bir inek-gün görünümünde birleştirmektedir. Sentetik kohortta profil, laktasyon, süt, besleme, sensör, çevre ve sağlık olayı kayıtları önce `norm_*` tablolarına, ardından özellik, etiket ve model-girdi tablolarına yazılmaktadır. Toplam 136 ineğe ait 21 840 inek-gün satırı üzerinde 19 sınıflandırma modeli karşılaştırılmıştır. Aynı ineğe ait günlerin fold'lar arasında sızmasını engellemek için inek-gruplu beş katlı çapraz doğrulama kullanılmış; model seçimi, %4,52 pozitif sınıf oranına uygun olarak PR-AUC üzerinden yapılmıştır. Ana deneyde linear discriminant analysis (LDA), 0.7411 ± 0.0285 CV PR-AUC ve 0.6927 test PR-AUC ile seçilmiştir. En iyi dört modelin beş tekrar ve beş fold ile yapılan doğrulamasında Torch ResNet ile LDA'nın pratikte eşit olduğu, ancak LDA'nın daha iyi olasılık kalitesi ve çok daha düşük eğitim maliyeti sunduğu görülmüştür. Out-of-fold tahminlerle eğitilen sigmoid kalibrasyon, test Brier skorunu 0.0375'ten 0.0276'ya ve expected calibration error değerini 0.0365'ten 0.0076'ya düşürmüştür. SCC ablation ve özellik-grubu deneyleri, mevcut sentetik/proxy veride süt özelliklerinin baskın olduğunu göstermiştir. Sonuçlar çalışır ve tekrar üretilebilir bir karar destek altyapısını doğrulamakla birlikte, etiketlerin tamamı sentetik/proxy olduğundan gerçek çiftlik performansı veya klinik tanı başarısı olarak yorumlanmamalıdır. Ayrıca sayısal model sonuçları, raporlanan notebook çalıştırmasına aittir; veri üretim tanımı değiştirildiğinde tam eğitim ve değerlendirme akışı yeniden çalıştırılmalıdır.**

***Anahtar Kelimeler*—LaktaFeed-Risk, süt sığırcılığı, enerji açığı riski, inek-gruplu çapraz doğrulama, PR-AUC, olasılık kalibrasyonu, ablation, derin tabular öğrenme**

I. Giriş

Modern süt sığırcılığında işletme karlılığı, hayvan refahı ve üretim sürekliliği birbirinden bağımsız hedefler değildir. Günlük yemleme planı, süt verimi ve yem maliyeti üzerinde doğrudan etkiye sahip olmakla birlikte, metabolik bozukluklar, meme sağlığı, enerji açığı ve ısı stresi gibi risklerin erken yönetilmesinde de kritik rol oynar. Özellikle yüksek verimli ineklerde laktasyon evresi, kuru madde alımı, vücut kondisyon skoru, süt yağ/protein oranı, somatik hücre sayısı, elektriksel iletkenlik ve davranışsal sensör ölçümleri birlikte ele alındığında, besleme kararı yalnızca rasyon formülasyonu değil, aynı zamanda öngörücü sağlık yönetimi problemidir.

Bu çalışmada söz konusu sağlık riski ve besleme ihtiyacı tahmin bileşeni **LaktaFeed-Risk** olarak adlandırılmıştır. LaktaFeed-Risk'in ürettiği skorları rasyon seçimi ve reward hesabına taşıyan optimizasyon bileşeni ise **LaktaFeed-Opt** olarak konumlandırılır. Bu adlandırma, raporda risk tahmini katmanı ile rasyon optimizasyonu katmanını açık biçimde ayırmak için kullanılmıştır.

LaktaFeed-Risk bu problemi inek-gün düzeyinde ele alır. Amaç, her bir inek için belirli bir günün üretim, laktasyon, sensör, çevre ve besleme özelliklerini kullanarak sağlık riski ve besleme ihtiyacı sinyalleri üretmektir. Bu sinyaller LaktaFeed-Opt'ta kullanılacak rasyon optimizasyonu ve politika/reward katmanı için girdi sağlar. Başka bir ifadeyle LaktaFeed-Risk, "inek bugün hangi risk ve besleme ihtiyacı profilinde?" sorusuna cevap üretir; LaktaFeed-Opt ise bu cevabı kullanarak "bu profil için hangi rasyon/aksiyon daha uygundur?" sorusunu ele alır.

Literatürde süt sığırcılığı sağlık tahmini için çok sayıda klasik makine öğrenmesi ve ensemble modelinin kullanıldığı görülmektedir. Klinik mastitis tahmini üzerine yapılan karşılaştırmalı çalışmalarda random forest, multilayer perceptron, support vector machine, decision tree, gradient boosting, AdaBoost, linear discriminant analysis, logistic regression ve naive Bayes gibi modellerin birlikte değerlendirildiği raporlanmıştır [1]. Otomatik sağım sistemlerinden gelen zaman serisi verilerle mastitis durumunun tahmin edildiği çalışmalarda logistic regression, SVM, decision tree, random forest, gradient boosting ve MLP gibi modeller karşılaştırılmıştır [2]. Mastitis riskini zaman serisi özellikleriyle ele alan başka bir çalışma ise XGBoost, GBDT, SVM, KNN, logistic regression ve LSTM modellerini birlikte incelemiştir [3]. Bu çalışmalar, LaktaFeed-Risk için tek bir model ailesine bağlı kalmak yerine geniş bir model kayıt yapısı tasarlamayı gerekli kılar.

Mastitis, ketozis ve meme sağlığı literatürü; süt verimi, geviş getirme süresi, süt elektriksel iletkenliği, somatik hücre sayısı, yağ/protein oranı ve laktasyon özelliklerinin sağlık tahmininde önemli sinyaller taşıdığını göstermektedir [4]–[6]. Sensör-tabanlı güncel çalışmalar da metabolik ve meme sağlığı bozukluklarının karar ağacı, logistic regression, MLP, random

forest ve gradient boosting gibi denetimli modellerle erken tespit edilebileceğini göstermektedir [7]. Besleme ve enerji dengesi tarafında ise kuru madde alımı, süt verimi, vücut ağırlığı ve laktasyon evresi temel belirleyiciler olarak öne çıkar [8], [9]. Vücut kondisyon skoru da enerji dengesi ve metabolik riskleri yorumlamak için pratik bir hayvan düzeyi göstergedir [10]. Bu nedenle LaktaFeed-Risk veri modeli, yalnızca süt verimi tablosunu değil, süt bileşenlerini, laktasyon evresini, BCS/BW proxy değerlerini, sensör günlük özetlerini ve çevresel THI değerlerini de özellik setine dahil eder.

A. Katkılar ve Beklenen Etki Alanları

LaktaFeed-Risk'in katkısı yalnızca bir sınıflandırma veya regresyon modeli eğitmekten ibaret değildir. Sistem, süt sığırcılığında üretim, hayvan refahı, çiftlik ekonomisi, gıda güvenliği, iklim etkisi ve sosyal kapsayıcılık arasında kurulan zor dengeye veri-temelli bir karar destek katmanı eklemeyi amaçlar. FAO'ya göre dünya genelinde yaklaşık 150 milyon hane süt üretimiyle ilgilenir; süt üretimi özellikle gelişmekte olan ülkelerde hane geçimi, gıda güvenliği, beslenme ve hızlı nakit akışı için önemlidir [11]. Dünya Bankası da hayvancılığı küresel gıda sisteminin temel bir bileşeni olarak tanımlar; sektörün tarımsal çıktı değerinin önemli bir bölümünü oluşturduğunu ve yaklaşık 1.3 milyar insanın geçim ve beslenme güvenliğini desteklediğini vurgular [12]. Bu ölçekte bir üretim sisteminde inek-gün düzeyindeki küçük verim, sağlık ve besleme kararları bile toplam ekonomik kayıp, süt arzı, çevresel yoğunluk ve kırılgan hanelerin gelir istikrarı üzerinde büyüyen etkilere sahiptir.

Bu çalışmanın ilk katkısı, sağlık riskini, besleme ihtiyacını ve kısa dönem süt verimini aynı inek-gün satırında birleştiren izlenebilir bir veri mimarisi sunmasıdır. Mevcut literatürde hassas hayvancılık yaklaşımlarının hayvan sağlığı, yem yönetimi, çevresel etki, izlenebilirlik ve karar destek süreçleri için kritik olduğu gösterilmiştir [13], [14]. LaktaFeed-Risk bu yönelimi somut bir PostgreSQL şeması, model-ready snapshot tablosu, özellik/etiket ayrımı, sentetik/proxy kaynak izleme politikası ve notebook üzerinden tekrar çalıştırılabilir eğitim akışıyla uygulanabilir hale getirir. Böylece çalışma, yalnızca model sonucu değil, sonradan denetlenebilen bir veri üretim ve deney protokolü de önerir.

İkinci katkı, hayvan sağlığı ve refahı boyutundadır. WOAH, süt sığırcılığında mastitis, tırnak/ayak hastalıkları, üreme ve metabolik hastalıkları yetişkin süt inekleri için önemli sağlık problemleri olarak tanımlar; morbidite, mortalite, sürüden çıkarma, vücut kondisyonu, canlı ağırlık değişimi ve süt verimi düşüşünü refah durumunun doğrudan veya dolaylı göstergeleri arasında sayar [15]. Bu nedenle süt verimi, laktasyon evresi, BCS, geviş getirme, aktivite, yatma süresi, vücut sıcaklığı ve THI gibi sinyallerin tek bir risk skorunda toplanması, veteriner hekimin ve üreticinin geç fark edilen problemleri daha erken incelemesine yardım edebilecek bir erken uyarı altyapısıdır. Bu rapor klinik tanı veya mortalite azaltımı kanıtı sunmaz; ancak mortalite ve zorunlu sürüden çıkarma ile ilişkili risk paternlerini izlenebilir hale getirecek deneysel zemini kurar.

Üçüncü katkı, ekonomik kayıpların sistematik ölçülmesine ve azaltılmasına yöneliktir. Global Burden of Animal Diseases çizgisindeki güncel bir ekonomik analiz, 183 süt üreten ülkede 12 temel süt sığırı hastalığının yıllık küresel kaybını yaklaşık 65 milyar ABD doları olarak tahmin etmiş; subklinik ketozis, klinik mastitis ve subklinik mastitisin en maliyetli başlıklar olduğunu raporlamıştır [16]. Mastitis literatürü de azalan süt verimi ve kalitesi, atılan süt, tedavi/işçilik maliyeti, kısalan üretken ömür ve sürüden çıkarma nedeniyle mastitisin en maliyetli süt sığırı hastalıklarından biri olduğunu göstermektedir [17]. Lameness maliyeti üzerine yapılan derlemeler de satılamayan süt, verim kaybı, üreme performansı düşüşü, hayvan ölümü, sürüden çıkarma ve refah kaybını aynı ekonomik çerçevede ele alır [18]. LaktaFeed-Risk, bu kayıpların her birini doğrudan ortadan kaldırdığını iddia etmez; fakat risk skorlarını rasyon ve bakım aksiyonlarına bağlayarak kayıp oluşmadan önce karar alınabilecek bir operasyonel pencere açmayı hedefler.

Dördüncü katkı, gıda güvenliği ve beslenme bağlamındadır. Birleşmiş Milletler Sürdürülebilir Kalkınma Hedefi 2, açlığın sona erdirilmesi, gıda güvenliği, iyileştirilmiş beslenme ve sürdürülebilir tarımı birlikte ele alır; 2025 SDG izleme metinleri ise gıda sistemlerinin daha sürdürülebilir, kapsayıcı ve dirençli hale getirilmesini acil bir ihtiyaç olarak vurgular [19]. FAO, süt ve süt ürünlerinin yoksul topluluklarda beslenme ve geçim olanaklarını iyileştirme potansiyeline dikkat çeker [20]. Bu çerçevede LaktaFeed-Risk, daha istikrarlı süt üretimi ve daha erken sağlık yönetimi üzerinden yalnızca çiftlik karlılığına değil, yerel süt arzının sürekliliğine ve besleyici gıdaya erişimin dayanıklılığına da katkı verebilecek bir altyapı olarak konumlandırılır.

Beşinci katkı, sosyal adalet, kırsal yoksulluk ve toplumsal cinsiyet boyutuna uzanır. FAO, birçok kırsal toplulukta kadınların sağım, besleme, toplama, işleme ve pazarlamada önemli rol aldığını; süt gelirinin çoğu zaman gıda, giyim, çocuk eğitimi ve temel sağlık giderleri için kullanıldığını belirtir [21]. Bu nedenle küçük ve orta ölçekli işletmelerde sağlık kaynaklı ani verim düşüşünü azaltabilecek karar destek sistemleri, yalnızca teknik üretim aracı değil, hane gelirinin düzenliliğini ve kırılgan grupların dayanıklılığını destekleyebilecek kapsayıcı dijital tarım bileşenleridir. Bu ilişki, SDG 1'deki yoksulluğun azaltılması, SDG 5'teki toplumsal cinsiyet eşitliği ve SDG 8'deki insana yakışır iş ve ekonomik büyüme hedefleriyle doğrudan bağlantılıdır [22]–[24].

Altıncı katkı, iklim ve kaynak verimliliği boyutundadır. FAO, hayvancılık tedarik zincirlerinin küresel antropojenik sera gazı emisyonlarının yaklaşık %14.5'inden sorumlu olduğunu, sığırın bu toplamda büyük pay taşıdığını ve emisyonların yem üretimi, enterik fermantasyon, gübre yönetimi ve arazi kullanımı değişiminden kaynaklandığını belirtir [25]. Dünya Bankası da hayvancılıkta verimlilik artışı, dengeli rasyon, sürdürülebilir yem tedariki, hayvan sağlığı ve refahı ile daha iyi gübre yönetimini iklim-akıllı hayvancılık için temel kaldıraçlar arasında sayar [12]. LaktaFeed-Risk'in LaktaFeed-Opt ile bağlanması bu noktada önemlidir: risk skorları yalnızca hastalık alarmı değil, gereksiz yemleme,

enerji açığı, verim düşüşü ve potansiyel kaynak israfını aynı karar katmanında değerlendirebilecek bir optimizasyon girdisine dönüşür. Böylece çalışma, SDG 12'nin sorumlu üretim/tüketim ve SDG 13'ün iklim eylemi çerçevesiyle savunulabilir bir bağ kurar [26], [27].

Yedinci katkı, One Health ve antimikrobiyal direnç perspektifidir. WHO, antimikrobiyal direncin insan, hayvan ve bitki sağlığını birlikte ilgilendiren küresel bir tehdit olduğunu; dirençli enfeksiyonların hayvan sağlığını ve çiftlik verimliliğini etkileyerek gıda güvenliğini de tehdit ettiğini belirtir [28]. FAO'nun süt üretiminde antibiyotiklerin sorumlu kullanımına ilişkin yayını, doğru yetiştiricilik uygulamalarıyla hayvan sağlığının iyileştirilebileceğini ve antibiyotik kullanım ihtiyacının azaltılabileceğini vurgular [29]. LaktaFeed-Risk bu bağlamda tedavi öneren bir sistem değil, önleyici yönetim kararlarını veriyle destekleyerek veteriner hekim denetiminde daha hedefli müdahaleye zemin hazırlayan bir karar destek katmanıdır.

Son olarak, çalışmanın metodolojik katkısı şeffaflık ve tekrar üretilebilirliktir. Sentetik/proxy değerlerin ham gözlem gibi sunulmaması, kaynak kodu ile etiketlenmesi, model kayıt yapısının genişletilebilir tutulması, aynı veri bölme ve metrik protokolüyle çok sayıda model ailesinin karşılaştırılması ve deneysel sonuçlar bölümünün klinik doğrulama yapılmadan performans iddiasına dönüştürülmemesi, yapay zeka tabanlı karar destek sistemleri için gerekli raporlama disiplinini güçlendirir [30]–[32]. Bu nedenle LaktaFeed-Risk'in iddiası, tek başına "en yüksek AUC" üretmek değil; hayvan, üretici, tüketici ve çevre açısından etkisi olan kararları ölçülebilir, denetlenebilir ve geliştirilebilir hale getiren bir süt sığırcılığı karar destek omurgası kurmaktır.

TABLE I
LAKTAFEED-RISK'IN KATKI ALANLARI VE KÜRESEL GÜNDEMLE İLIŞKISI

Katkı alanı	Savunulabilir dayanak ve LaktaFeed-Risk karşılığı
Hayvan sağlığı ve refahı	WOAH'ın morbidite, mortalite, sürüden çıkarma, BCS ve süt verimi göstergeleriyle uyumlu erken uyarı skoru [15].
Ekonomik dayanıklılık	Yaklaşık 65 milyar ABD doları/yıl olarak tahmin edilen süt sığırı hastalık kayıplarına karşı, risk gerçekleşmeden önce bakım ve rasyon kararını gözden geçirme zemini [16].
Gıda güvenliği	Süt üretiminin hane geçimi ve beslenmedeki rolüyle, SDG 2 çerçevesinde daha istikrarlı yerel süt arzına katkı [11], [19].
Sosyal adalet	Süt gelirinin kadınlar ve kırılgan haneler için eğitim, gıda ve temel sağlık harcamalarını desteklemesi nedeniyle düşük maliyetli karar destek protokolü [21].
İklim ve kaynak verimliliği	Rasyon dengesi, verimlilik ve sürdürülebilir yem yönetimiyle LaktaFeed-Opt'a aktarılabilir risk/ihtiyaç skorları [25].
One Health ve AMR	Önleyici sağlık yönetimi ve hedefli veteriner müdahalesi için AMR duyarlı veri katmanı [28], [29].
Tekrar üretilebilirlik	Kaynak izlenebilirliği, sentetik/proxy ayrımı, model kayıt yapısı ve ortak metrik protokolü [30]–[32].

B. Araştırma Soruları ve Kapsam

Bu raporun deneysel sonuçlardan önce yanıtlamayı hedeflediği araştırma soruları aşağıdaki gibidir:

- **AS1:** Çok kaynaklı süt sığırcılığı verileri, inek-gün düzeyinde sağlık riski ve besleme ihtiyacı tahmini için izlenebilir bir model-ready şemaya dönüştürülebilir mi?
- **AS2:** Mastitis, ketozis, meme sağlığı ve yapısal veri tahmini literatüründe kullanılan model aileleri tek bir eğitim kayıt yapısında karşılaştırılabilir hale getirilebilir mi?
- **AS3:** LaktaFeed-Risk'in risk/ihtiyaç tahmin çıktısı, LaktaFeed-Opt rasyon optimizasyonu için state ve reward üretim zincirine bağlanabilir mi?

Bu çalışmada canlı çiftlik entegrasyonu, gerçek zamanlı alarm validasyonu ve klinik tanı iddiası kapsam dışıdır. Mevcut veri seti sentetik/proxy alanlar içerdiğinden rapor, model performansı iddiasından çok veri-mimari ve deney protokolü tasarımına odaklanır. Bu ayrım özellikle önemlidir; çünkü yapay zeka tabanlı karar destek sistemleri için erken aşama raporlamada kullanım amacı, hedef popülasyon, veri kaynağı, validasyon tasarımı ve insan karar sürecindeki rol açık biçimde belirtilmelidir [30], [32].

II. METOT

A. Genel Sistem Mimarisi

LaktaFeed-Risk, LaktaFeed-Opt içindeki rasyon optimizasyonunun yerine geçen bir aksiyon seçici değildir; bu optimizasyon katmanını besleyen risk ve ihtiyaç çıkarım altyapısıdır. Mimari bu nedenle iki soruyu bilinçli olarak ayırır: LaktaFeed-Risk "inek-gün kaydının sağlık ve besleme profili nedir?" sorusuna cevap üretir; LaktaFeed-Opt ise bu cevabı kullanarak "bu profil için hangi rasyon veya aksiyon daha uygundur?" sorusunu çözer. Bu ayrım, sağlık tahmini ile rasyon optimizasyonunun hem teknik hem de sorumluluk sınırlarını netleştirir. Risk modeli doğrudan tedavi veya rasyon değişikliği emri üretmez; ölçülebilir, izlenebilir ve uzman tarafından yorumlanabilir skorlar üretir.

Sistemin merkezinde **inek-gün** kavramı bulunur. Farklı kaynaklardan gelen süt, laktasyon, sağlık, sensör, çevre ve besleme kayıtları farklı zaman çözünürlüklerine sahip olsa da model eğitiminde tek bir ortak satır yapısına indirgenir: belirli bir ineğin belirli bir gündeki gözlenebilir durumu. Böylece ham veri dağınık olsa bile modelin gördüğü örnek, süt verimi, laktasyon evresi, geviş getirme, aktivite, vücut sıcaklığı, THI, BCS ve besleme proxy'lerini aynı karar anında birleştiren tek bir snapshot olur. Bu yaklaşım, hem veri sızıntısı kontrolünü kolaylaştırır hem de çıktının çiftlik operasyonunda yorumlanmasını basitleştirir.

Uçtan uca veri akışı aşağıdaki mantıkla ilerler:

$$\begin{aligned}\text{Kaynaklar} &\rightarrow \text{Raw tablolar} \rightarrow \text{Normalize tablolar} \\ &\rightarrow \text{Özellik/etiket tabloları} \rightarrow \text{Model eğitimi} \\ &\rightarrow \text{Tahmin skorları} \rightarrow \text{LaktaFeed-Opt girdisi}.\end{aligned} \tag{1}$$

Bu zincirin her adımı farklı bir sorumluluk taşır. Raw katmanı "ne geldi?" sorusunu, normalize katmanı "aynı inek-gün eksenine nasıl oturdu?" sorusunu, özellik/etiket katmanı "model hangi girdiyi ve hangi hedefi gördü?" sorusunu, model katmanı ise "bu girdiden hangi risk/ihtiyaç skoru üretildi?" sorusunu

yanıtlar. Böylece hata analizi yaparken problem tek bir büyük SQL veya notebook içinde aranmaz; hangi katmanda oluştuğu ayrıştırılabilir.

Mimari altı ana katmandan oluşur:

1) **Kaynak ve katalog katmanı:** süt, laktasyon, sağlık, sensör, çevre ve yem referans kaynakları `meta_veri_kaynagi` üzerinden kataloglanır. Amaç yalnızca dosya yüklemek değil, her kaydın nereden geldiğini, hangi amaçla kullanıldığını ve gözlenen mi sentetik/proxy mi olduğunu izlenebilir kılmaktır.
2) **Raw gözlem katmanı:** dış dosya, API veya elle hazırlanan kaynak çıktıları `raw_*` tablolarına mümkün olduğunca bozulmadan yüklenir. Bu katmanda veri temizlenmiş gibi gösterilmez; eksik, düzensiz veya parçalı veri daha sonraki katmanlarda açıkça ele alınır.
3) **Normalize entegrasyon katmanı:** inek profili, laktasyon, süt, sağlık, sensör ve çevre kayıtları ortak anahtarlara ve ortak zaman eksenine yaklaştırılır. Bu katman, farklı kaynaklardaki inek kimliklerini, tarihleri ve ölçüm frekanslarını aynı analitik dile çevirir.
4) **Özellik ve etiket katmanı:** model-ready omurga olan `feat_cow_day_snapshot` üretilir; sağlık riski hedefleri `feat_health_risk_label`, besleme ihtiyacı hedefleri ise `feat_feeding_need_label` üzerinden ayrıştırılır. Bu ayrım, model girdileri ile hedef değişkenlerin karışmasını ve gelecek bilgisi sızıntısını önlemek için kritiktir.
5) **Eğitim, değerlendirme ve model çıktısı katmanı:** notebook ve `code/` altındaki Python modülleri, `feat_cow_day_snapshot` tablosunu sağlık, besleme ve son tahmin tablolarıyla birleştirerek eğitim veri çerçevesini oluşturur. `feat_model_input_a` ise aynı inek-gün durumunu özellik/hedef JSON yapısıyla saklayan denetim ve dışa aktarım tablosudur. Model kayıt yapısı sayesinde yeni bir algoritma eklemek için veri hattının yeniden yazılması gerekmez.
6) **Tahmin ve optimizasyon aktarım katmanı:** eğitilen veya kural-tabanlı çalışan risk modeli, inek-gün düzeyindeki skorlarını `feat_prediction_a` benzeri tahmin tablolarına yazar. LaktaFeed-Opt, bu skorları durum ve reward üretiminde kullanarak rasyon alternatiflerini yalnızca maliyet ve süt verimi açısından değil, sağlık riski ve besleme ihtiyacı açısından da değerlendirebilir.

Bu mimarinin en önemli tasarım ilkesi, ham gözlem ile sentetik/proxy tamamlamayı karıştırmamaktır. Mevcut veri setinde bazı alanlar veri hattının uçtan uca çalışmasını göstermek için sentetik veya proxy olarak doldurulmuştur; bu alanlar model performansını klinik gerçeklik gibi sunmak için değil, veri şeması, eğitim akışı ve optimizasyon bağlantısının test edilebilmesi için kullanılır. Dolayısıyla bir model sonucu değerlendirilirken yalnızca AUC, F1 veya RMSE gibi metriklere bakmak yeterli değildir. Sonucun hangi kaynaklardan beslendiği, hangi özelliklerin gözlenen veri olduğu, hangilerinin proxy olduğu, veri bölme politikasının zamansal sızıntı üretip üretmediği ve skorun LaktaFeed-Opt tarafında nasıl kullanılacağı birlikte incelenmelidir.

TABLE II
LAKTAFEED-RISK SISTEM KATMANLARI

Katman	Sorumluluk ve çıktı
Kaynak ve katalog	Veri kaynağını, kullanım amacını ve gözlenen/proxy ayrımını `meta_veri_kaynagi` ile kayıt altına almak.
Raw gözlem	Gelen veriyi ham yapısıyla korumak ve yeniden yüklenebilir hale getirmek; `raw_milk`, `raw_health`, `raw_sensor` ve çevre tablolarını beslemek.
Normalize entegrasyon	Kimlik, tarih ve ölçüm frekansı farklarını ortak inek-gün eksenine yaklaştırmak; `norm_*` tablolarını üretmek.
Özellik/etiket	Model girdisi ile hedef değişkenleri ayrıştırmak ve veri sızıntısı riskini azaltmak; snapshot ve etiket tablolarını hazırlamak.
Eğitim ve değerlendirme	Model seçimi, ön işleme, eğitim/test bölmesi, metrik, grafik ve kaydedilebilir model çıktısı üretmek.
Tahmin/optimizasyon aktarımı	Risk ve ihtiyaç skorlarını rasyon optimizasyonuna taşımak; `feat_prediction_a` ve LaktaFeed-Opt durum ve reward girdilerini beslemek.

Operasyonel bakışla sistemin beklenen çalışma biçimi şöyledir: önce günlük veri yüklenir, sonra inek-gün snapshot'ları güncellenir, ardından eğitimli model her inek için risk ve besleme ihtiyacı skorları üretir. Üretici veya uzman, bu skorları tek başına karar olarak değil, inceleme önceliği ve rasyon değerlendirme girdisi olarak kullanır. Böylece LaktaFeed-Risk, çiftlikte gözden kaçabilecek erken sinyalleri öne çıkaran; LaktaFeed-Opt ise bu sinyalleri ekonomik ve besleme kısıtlarıyla birlikte yorumlayan tamamlayıcı bir karar destek zinciri oluşturur.

B. Problem Tanımı

LaktaFeed-Risk, bir inek-gün kaydını sağlık riski, besleme ihtiyacı ve kısa dönem üretim beklentisine dönüştüren denetimli öğrenme problemidir. Buradaki amaç, geçmişte veya aynı gün gözlenebilen sinyalleri kullanarak geleceğe dönük bir karar destek skoru üretmektir. Modelin temel örneği belirli bir inek (i) ve belirli bir tarih (t) için oluşturulan tek satırlık snapshot'tır. Bu snapshot, modelin karar anında görebileceği bilgileri temsil eder; t sonrasındaki sağlık olayı, sonraki gün süt verimi veya LaktaFeed-Opt çıktısı girdi olarak kullanılmaz.

Her inek i ve gün t için model girdisi

$$\mathbf{x}_{i,t} = [\mathbf{x}_{i,t}^{milk}, \mathbf{x}_{i,t}^{lac}, \mathbf{x}_{i,t}^{feed}, \mathbf{x}_{i,t}^{sensor}, \mathbf{x}_{t}^{env}] \tag{2}$$

şeklinde tanımlanır. Burada süt değişkenleri günlük süt verimi, yağ/protein oranı, somatik hücre sayısı ve elektriksel iletkenlik gibi üretim ve meme sağlığı sinyallerini; laktasyon değişkenleri DIM, laktasyon evresi, parity, gebelik durumu, BCS ve vücut ağırlığını; besleme değişkenleri tahmini kuru madde alımı, rasyon tipi ve yem oranlarını; sensör değişkenleri geviş getirme, aktivite, yatma süresi, vücut sıcaklığı ve su tüketimini; çevre değişkenleri ise sıcaklık, nem ve THI değerlerini kapsar. Bu ayrım, modelin hangi biyolojik ve operasyonel sinyal grubundan beslendiğini açıkça gösterir.

Çalışmada üç farklı tahmin görevi aynı veri omurgası üzerinde ele alınır. Birinci görev, sağlık riski için ikili sınıflandırmadır:

$$\hat{p}_{i,t,k,h}^{risk} = P(y_{i,t,k,h}^{risk} = 1 \mid \mathbf{x}_{i,t}) \tag{3}$$

Burada k risk türünü, h ise tahmin ufkunu temsil eder. Uygulamadaki ikili hedefler `energy_deficit_high`, `ketosis_7d`, `ketosis_14d`, `mastitis_7d`, `mastitis_14d`, `asidosis_7d` ve `early_warning_flag` alanlarıdır. Bu çıktı, "bu inek için yakın dönemde hangi sağlık riski izlenmeli?" sorusuna olasılıksal bir cevap verir.

İkinci görev, besleme ihtiyacı sınıfının tahmin edilmesidir:

$$\begin{aligned} &\hat{y}_{i,t}^{need} \in \mathcal{C}^{need}, \\ &\mathcal{C}^{need} = \{\texttt{high_energy}, \texttt{protein_support}, \\ &\qquad \texttt{maintenance}, \texttt{transition_support}, \\ &\qquad \texttt{risk_balanced}\}. \end{aligned} \tag{4}$$

Bu hedef `feeding_need_class` alanıyla temsil edilir ve LaktaFeed-Opt tarafında rasyon adaylarının hangi fizyolojik/operasyonel ihtiyaca göre değerlendirileceğini belirleyen durum bilgisinin önemli bir parçasıdır.

Üçüncü görev, kısa dönem süt verimi regresyonudur:

$$\hat{y}_{i,t+1}^{milk} = f(\mathbf{x}_{i,t}). \tag{5}$$

Bu görev `next_day_milk_yield_kg` hedefiyle temsil edilir ve rasyon kararının üretim etkisini yorumlamak için kullanılır. Sağlık riski yüksek olan bir inekte yalnızca süt verimini artırmaya çalışan bir karar destek sistemi yanıltıcı olabilir; bu nedenle LaktaFeed-Risk sağlık, besleme ihtiyacı ve üretim beklentisini birlikte ele alır.

Bu problem tanımı klinik tanı iddiası taşımaz. Model çıktısı, veteriner hekim veya çiftlik uzmanı için inceleme önceliği oluşturan bir karar destek sinyalidir. Başarılı bir LaktaFeed-Risk modeli yalnızca yüksek metrik üreten model değil, aynı zamanda yanlış alarm maliyeti, kaçırılan risk maliyeti, kalibrasyon kalitesi ve LaktaFeed-Opt'a aktarılabilirliği birlikte kabul edilebilir olan modeldir.

C. Özellik Grupları ve Beklenen Klinik/Operasyonel Anlam

Özellik seti yalnızca istatistiksel değişkenler listesi olarak değil, biyolojik ve operasyonel anlamı olan gruplar halinde tasarlanmıştır. Süt verimi ve süt bileşenleri üretim düzeyi ile meme/metabolik risk sinyallerini; laktasyon evresi ve DIM fizyolojik dönemi; BCS ve vücut ağırlığı enerji rezervini; geviş getirme, aktivite ve yatma süresi davranışsal değişimi; THI ise çevresel ısı stresini temsil eder. Bu gruplama hem model yorumlanabilirliğini hem de sonradan yapılacak özellik çıkarma/ablasyon deneylerini kolaylaştırır.

D. Veri İşleme ve Özellik Üretimi

Veri hattı iki ayrı üretim kolundan oluşmaktadır. Birinci kol, dış kaynaklardan gelen gözlenen kayıtları `raw_*` tablolarına mümkün olduğunca değiştirmeden yükler. MmCows süt, sağlık, vücut sıcaklığı, THI, ankle, UWB, IMMU ve pressure kayıtları bu katmanda korunur. Yüksek frekanslı sensör kayıtları bağımsız eğitim satırı olarak çoğaltılmaz; önce inek-gün düzeyinde hareket mesafesi, ivme büyüklüğü, basınç ve yükseklik istatistiklerine özetlenir. Gözlenen 16 inek x 15 günlük süt omurgasındaki eksik profil, süt bileşeni, besleme ve sağlık alanları proxy kurallarla tamamlanır ve satırlar MmCows-proxy kaynak kökeniyle işaretlenir.

TABLE III
ÖZELLIK GRUPLARI VE KARAR DESTEK ANLAMI

Grup	Örnek sinyaller ve beklenen kullanım
Üretim ve süt bileşeni	Süt verimi, yağ/protein oranı, SCC ve elektriksel iletkenlik; mastitis, metabolik risk ve üretim düşüşü sinyali.
Laktasyon ve profil	DIM, laktasyon evresi, parity, gebelik durumu, BCS ve vücut ağırlığı; enerji dengesi ve dönemsel ihtiyaç normalizasyonu.
Besleme proxy'leri	Tahmini DMI, kuru madde yüzdesi ve rasyon tipi; enerji açığı ve besleme ihtiyacı sınıfı üretimi.
Davranış ve sensör	Rumination, aktivite, yatma süresi, vücut sıcaklığı ve su tüketimi; erken sağlık sapması ve refah sinyali.
Çevre	THI, sıcaklık ve nem; ısı stresinin süt verimi ve sağlık riskiyle ilişkilendirilmesi.

İkinci kol, model geliştirme ve veri hattı stres testi için gözlenen satırlardan ayrı bir longitudinal sentetik kohort üretir. Bu üretim süreci, sentetik kayıtları doğrudan final tabloya yazmak yerine normalize katmanı da dolduracak şekilde tasarlanmıştır. Deterministik pseudo-random bileşenler kullanılarak 120 sentetik inek için 180 günlük bir ızgara oluşturulur. İnek yatkınlığı, DIM, THI, dönemsel risk epizotları ve günlük gürültüden sentetik bir latent risk türetilir. Bu risk ve laktasyon eğrisi kullanılarak süt verimi, BCS, süt bileşenleri, SCC, DMI, geviş getirme, aktivite, yatma süresi, vücut sıcaklığı, su tüketimi ve çok-modlu sensör özetleri üretilir.

Üretilen sentetik değişkenler doğrudan yalnızca final snapshot tablosuna yazılmaz. Önce inek profili, çevre, laktasyon, süt, besleme, sensör ve sağlık olayı için normalize tablolar doldurulur. Daha sonra bu normalize katmanlardan inek-gün snapshot'ı, 7/14/30 günlük süt trendleri, sağlık ve besleme etiketleri, model-girdisi denetim kayıtları ve kural-tabanlı tahmin kayıtları türetilir. Böylece sentetik veri de gerçek veri geldiğinde kullanılacak aynı normalize–özellik–model arayüzünü izler.

Sağlık hedefleri iki farklı mantığa sahiptir. Ketozis, mastitis, asidoz ve metritis etiketleri, sentetik sağlık olayı kayıtlarında ilgili olayın mevcut günden sonraki 7 veya 14 günlük pencere içinde bulunup bulunmadığına göre üretilir ve ileri-olay kökenli sentetik etiket olarak işaretlenir. Bu raporda modellenen `energy_deficit_high` hedefi ise aynı gün için üretilen sentetik latent risk seviyesinin "high" sınıfıdır; ileri dönem klinik olay etiketi değildir.

Model-ready ana tablo `feat_cow_day_snapshot` tablosudur. Python yükleyici bu tabloyu `feat_health_risk_label`, `feat_feeding_need_label` ve son `feat_prediction_a` kayıtlarıyla birleştirir. Kaynak seçimi `allowed_data_origins` ile sınırlandırılabilir; böylece yalnızca MmCows proxy omurgası veya yalnızca longitudinal sentetik kohort ayrı biçimde incelenebilir.

Yükleyici tahmin skorlarını denetim amacıyla veri çerçevesine dahil etse de eğitim özellik listesi bu skorları içermez; model yalnızca önceden tanımlanmış sayısal ve kat-

TABLE IV
KARŞILAŞTIRILAN TEMEL MODEL AILELERI

Model anahtarı	Kullanım gerekçesi
Logistic / Ridge	Yorumlanabilir ve hızlı referans model; sınıflandırmada logistic regression, regresyonda ridge.
LDA	Sınıflar arası doğrusal ayrımı ve ortak kovaryans yapısını kullanan hızlı olasılıksal model.
RBF-SVM	Küçük/orta ölçekli yapısal veride güçlü doğrusal olmayan sınır modeli [33].
Random Forest	Doğrusal olmayan etkileşimleri yakalayan, özellik önemleri üreten güçlü ağaç topluluğu [34].
Boosting ailesi	AdaBoost, XGBoost, LightGBM ve CatBoost ile farklı sıralı hata düzeltme stratejileri [35]–[37].
MLP ailesi	Klasik ve PyTorch tabanlı çok katmanlı sinir ağı karşılaştırmaları.
Torch ResNet	Artık bağlantılar kullanan güçlü derin tabular referans model [38].
TabNet	Dikkat tabanlı değişken seçimi yapan yorumlanabilir derin tabular model.

egorik snapshot alanlarını kullanır. Böylece mevcut tahmin çıktılarının yeni model girdisine dönüşmesi engellenir. Enerji açığı hedefi eksik olan satırlar eğitim öncesinde elenir. Hastalık hedeflerinde ise eksik etiket birleşimleri mevcut yükleyicide negatif sınıfa çevrilmektedir; bu nedenle ketozis, mastitis veya asidoz deneyleri çalıştırılmadan önce etiket kapsama ve takip-penceresi sansür kontrolü ayrıca yapılmalıdır.

E. Model Kayıt Yapısı Tasarımı

LaktaFeed-Risk'te eğitim akışı `train.py` içinde tutulurken, model tanımları `code/models/` altında modüler hale getirilmiştir. Bu tasarımın amacı, yeni bir model eklemek için eğitim akışını değiştirme ihtiyacını ortadan kaldırmaktır. Her model ailesi bir builder fonksiyonu ile tanımlanır; kayıt yapısı bu builder fonksiyonlarını model adı, desteklenen problem tipi ve ön işleme tercihiyle birlikte saklar.

Varsayılan literatür temelli model listesi `academic_top_10` alias'ı ile çağrılır. Bu liste, süt sağlığı ve yapısal veri risk tahmini literatüründe sık karşılaşılan ve pratik olarak karşılaştırılması gereken modelleri içerir. Tablo IV kayıt yapısındaki temel model ailelerini özetler.

Kayıt yapısı içinde ayrıca `decision_tree`, `hist_gradient_boosting`, `linear_svm`, `knn`, `gaussian_naive_bayes`, `extra_trees`, `gradient_boosting` ve regresyon hedefleri için `elastic_net` modelleri de mevcuttur. Model parametreleri `ProjectATrainingConfig.model_params` alanı ile dışarıdan verilir. Bu sayede örneğin random forest ağaç sayısı veya XGBoost derinliği notebook üzerinden değiştirilebilir:

```
ProjectATrainingConfig(
    model_names=["academic_top_10"],
    model_params={
        "random_forest": {
            "n_estimators": 500
        },
        "xgboost": {"max_depth": 3}
    }
)
```

F. Raporlama, Yanlılık ve Validasyon İlkeleri

Makine öğrenmesi tabanlı risk modellerinde yalnızca yüksek skor raporlamak yeterli değildir. Klinik tahmin modeli çalışmalarında veri kaynağının, hedef tanımının, eksik veri stratejisinin, veri bölme politikasının, model seçiminin, hiperparametrelerin, kalibrasyonun ve uygulanabilirlik sınırlarının açıkça raporlanması önerilmektedir [30]. Yanlılık riski ve uygulanabilirlik değerlendirmeleri de özellikle küçük, eksik veya sentetik veri içeren çalışmalarda gereklidir [31]. Bu nedenle LaktaFeed-Risk deney protokolü aşağıdaki ilkeleri benimser:

- **Kaynak izlenebilirliği:** Ham, normalize ve sentetik/proxy satırlar kaynak kodlarıyla ayrılır.
- **Sızıntı kontrolü:** Gelecek gün süt verimi veya LaktaFeed-Opt sonucundan türetilen alanlar LaktaFeed-Risk girdi özelliği olarak kullanılmaz.
- **Bölme açıklığı:** Test inekleri model seçiminden önce ayrılır; development inekleri üzerinde `StratifiedGroupKFold` uygulanır.
- **Nadir sınıf duyarlılığı:** Sağlık riskleri nadir olduğunda PR-AUC ve recall, accuracy'den daha öncelikli yorumlanır.
- **Operasyonel güvenlik:** Model çıktısı tanı değil, karar destek sinyalidir; çiftlik uzmanı onayı olmadan otomatik tedavi veya rasyon değişikliği önerisi olarak kullanılmaz.

G. Eğitim ve Değerlendirme Akışı

Notebook temelli eğitim akışı şu adımlardan oluşur:

1) PostgreSQL bağlantısı kurulur ve LaktaFeed-Risk veri seti okunur.
2) Hedef değişken, bölme yöntemi, model listesi ve model parametreleri seçilir.
3) Sayısal özellikler ortanca ile doldurma yöntemiyle, kategorik özellikler one-hot encoding ile hazırlanır.
4) Seçilen model ailesi hedef tipine göre sınıflandırıcı veya regresör olarak oluşturulur.
5) İnek bazlı train/validation/test ayrımı yapılır; test inekleri model seçimi dışında tutulur.
6) Development inekleri üzerinde beş katlı `StratifiedGroupKFold` uygulanır ve ana seçim metriği olarak CV PR-AUC kullanılır.
7) İkili sınıflandırmada PR-AUC, ROC-AUC, F1, precision, recall, accuracy, Brier score, log-loss ve ECE raporlanır.
8) Seçilen modelin out-of-fold olasılıkları ile sigmoid kalibrasyon eğitilir; kalibrasyon yalnızca dokunulmamış test ineklerinde değerlendirilir.
9) SCC ablation, özellik-grubu karşılaştırması ve en iyi dört model için beş tekrar x beş fold doğrulama çalıştırılır.
10) İsteğe bağlı olarak en iyi model, metrikler, tahminler ve config dosyaları `artifacts/` altına kaydedilir.

İkili sağlık hedeflerinde pozitif sınıflar nadir olabileceğinden ana karşılaştırma metriği varsayılan olarak PR-AUC seçilmiştir. PR-AUC, özellikle mastitis veya ketozis

TABLE V
NOTEBOOK ANA DENEYININ TEKRAR ÜRETILEBILIRLIK AYARLARI

Alan	Değer
Hedef / ana metrik	`energy_deficit_high` / PR-AUC
Bölme / seed	Cow-stratified / 42
Train / validation / test	%55 / %20 / %25; inek ayrık
Model seçimi	Development üzerinde 5-fold grup CV
Kalibrasyon	OOF skorları üzerinde sigmoid
Tekrarlı doğrulama	Seed 42–46; 5 tekrar x 5 fold
Son refit	Değerlendirme sonrası tüm veri, etkin
Artifact kaydı	Notebook ana çalıştırmasında kapalı

gibi az sayıda pozitif örnek içeren veri setlerinde ROC-AUC'ye göre uyarı kalitesini daha hassas yansıtır. F1 eşiği out-of-fold precision-recall eğrisinden seçilir ve test setinde uygulanır. Seçilen kaynak veya tarih filtresi sonrasında tek sınıflı kalan hedeflerde eğitim akışı kırılmasın diye `dummy_most_frequent` referans modele düşer ve AUC tipi metrikler boş bırakılır.

H. Deney Protokolü ve Tekrar Üretilebilirlik

Notebook'taki ana deney `energy_deficit_high` hedefini, iki izinli veri kaynağını ve sabit `random_state=42` değerini kullanır. Bölme yöntemi `cow_stratified`, test oranı %25 ve validation oranı %20'dir. `cow_stratified` uygulaması 2000 aday inek ataması üretir; satır oranlarını ve sınıf dağılımlarını hedef oranlara en fazla yaklaştıran, her bölümde iki sınıfı da içeren atamayı seçer. Train, validation ve test arasında inek çakışmasına izin verilmez.

Grup çapraz doğrulama etkin olduğunda train ve validation bölümleri birleştirilip development havuzu olarak kullanılır. Dolayısıyla isimlendirilmiş validation bölümü bağımsız bir nihai doğrulama kümesi değildir; model seçimi beş katlı `StratifiedGroupKFold` üzerinden development havuzunda yapılır ve test kümeleri yalnızca son değerlendirmede kullanılır. Sayısal ortanca doldurma, kategorik doldurma, one-hot encoding ve gerekli modellerde ölçekleme her fold'un eğitim tarafında kurulan pipeline içinde yeniden öğrenilir.

Ana deneyde model seçimi CV PR-AUC ortalamasıyla yapılır. Test sınıf eşiği, development out-of-fold tahminlerinde F1'i ençoklayan eşiktir. Sigmoid kalibratör de yalnızca bu out-of-fold tahminlerle eğitilir. Tekrarlı top-dört deneyinde seed değerleri 42–46 arasında değiştirilerek toplam 25 fold sonucu üretilir; bu fold'lar ortak gözlemler içerdiğinden istatistiksel olarak tamamen bağımsız örnekler değildir. Değerlendirme tamamlandıktan sonra seçilen model isteğe bağlı tam-veri refit işleminden geçirilir; bu işlem raporlanan test metriklerini değiştirmez.

Notebook model parametrelerini açıkça tanımlar: random forest, XGBoost ve LightGBM için 300 estimator; CatBoost için 300 iterasyon ve derinlik 5; sklearn MLP için $(64, 32)$ gizli katmanları; Torch MLP ve ResNet için 128 gizli boyut, üç katman, en fazla 100 epoch ve 12 epoch patience; TabNet için $n_d = n_a = 16$, üç adım, en fazla 100 epoch ve 10 epoch patience kullanılır. Bağımlılıklar `requirements.txt` ile tanımlansa da ana notebook çalıştırmasında artifact kaydı kapalıdır ve donanım bilgisi rapora otomatik yazılmamaktadır. Bu nedenle süre karşılaştırmaları aynı çalışma ortamı içindeki göreli maliyet olarak yorumlanmalıdır.

I. Açıklanabilirlik ve Model Seçim Kriterleri

LaktaFeed-Risk'te en iyi model yalnızca tek bir skorla seçilmez. Nihai model adayı aşağıdaki ölçütlerin birlikte değerlendirilmesiyle belirlenmelidir:

- hedefe uygun ana metrikte üstünlük (binary için PR-AUC, regression için RMSE/MAE);
- test setinde kararlı recall ve precision dengesi;
- özellik önemleri veya katsayılar üzerinden biyolojik olarak savunulabilir sinyaller;
- sentetik/proxy özelliklere aşırı bağımlılık göstermeme;
- LaktaFeed-Opt tarafında rasyon optimizasyonunu bozmayacak şekilde kalibre ve düzenli skor dağılımı üretme.

Ağaç topluluğu ve boosting modellerinde özellik önemleri raporlanır; lineer modellerde katsayı büyüklükleri incelenebilir. Daha büyük veri setlerinde permutation importance ve SHAP tabanlı açıklama katmanları ayrıca eklenmelidir.

J. LaktaFeed-Opt ile Bağlantı

LaktaFeed-Risk çıktısı yalnızca raporlama amaçlı değildir. Nihai mimaride LaktaFeed-Risk modeli her inek-gün için sağlık riski ve besleme ihtiyacı skorları üretir; bu skorlar `feat_prediction_a` tablosuna yazılır. LaktaFeed-Opt rasyon optimizasyon katmanı, bu tahmin satırlarını `source_prediction_id` üzerinden kullanarak rasyon adayı, durum, aksiyon ve reward kayıtları üretir. Bu prototipte bağlantı kural tabanlı sentetik LaktaFeed-Risk çıktılarıyla kurulmuştur. Gerçek eğitim tamamlandığında beklenen sonraki adım, notebook'ta seçilen en iyi LaktaFeed-Risk modelinin skorlarını yeni bir `run_id` ile `feat_prediction_a` tablosuna aktarmaktır.

III. VERI SETI

A. Veri Kaynakları ve Kapsam

Smart Feed veri havuzu, dış kaynaklardan gelen süt, laktasyon, sağlık, sensör, çevre ve yem referans verilerini PostgreSQL içinde `ml_smart_feed` şeması altında birleştirir. İlk kol, 16 ineğe ait 15 günlük 240 inek-gün MmCows süt omurgasını kullanır [39]. Bu satırlarda süt verimi ve günlük özetlenebilen sensör ölçümleri gözlenen kayıtlardan gelirken, eksik model alanları ve sağlık etiketleri proxy kurallarla tamamlanır. İkinci kol, 120 inek x 180 günlük bağımsız longitudinal sentetik kohorttur. Bu kohort yalnızca final özellik tablosu üretmez; PostgreSQL veri yapısındaki normalize kayıtları, gelecek-pencereli sağlık etiketlerini, süt trendlerini, model-input ve tahmin kayıtlarını da üretir. Nihai deney veri seti 136 inek ve 21 840 inek-gün satırından oluşmaktadır.

MmCows kaynak modaliteleri bütün inekleri eşit biçimde kapsamamaktadır; özgün veri setinde görsel kayıtlar 16 ineği içerirken giyilebilir sensör kayıtları daha dar bir inek altkümesinde bulunmaktadır [39]. Bu nedenle final snapshot

TABLE VI
DENEY VERI KAYNAKLARININ KAPSAMI

Kaynak	İnek	İnek-gün
mmcows_observed_with_proxy	16	240
synthetic_longitudinal_v1	120	21 600
Toplam	**136**	**21 840**

TABLE VII
LONGITUDINAL SENTETIK KOHORTUN VERI KATMANLARI

Tablo/katman	Satır
norm_cow_profile	120
norm_environment_daily	213
norm_lactation/milk/feeding/sensor_daily	21 600 / tablo
norm_health_event	500
feat_cow_day_snapshot	21 600
feat_milk_trend	21 600
feat_health/feeding_label	21 600 / tablo
feat_model_input_a	21 600

TABLE VIII
HEDEF VE BÖLME DAĞILIMLARI

Küme	Satır	İnek	Pozitif
Train	12 000	74	542
Validation	4 380	28	194
Development	16 380	102	736
Test	5 460	34	252
Toplam	**21 840**	**136**	**988**

tablosundaki yüksek özellik doluluk oranı, yalnızca ham gözlem kapsamını değil, günlük özetleme ve açıkça işaretlenmiş proxy tamamlamayı da yansıtır.

B. Sentetik/Proxy Veri Politikası

Sentetik/proxy üretim eksik alanları gerçek gözlem gibi sunmak için değil, LaktaFeed-Risk ve LaktaFeed-Opt yazılım hattını uçtan uca çalıştırmak ve deney tasarımını sınamak için kullanılmaktadır. Bu politika dört ilkeye dayanır:

1) Gözlenen ham veri hiçbir aşamada sentetik değerle ezilmez.
2) Sentetik/proxy satırlar `data_origin`, `label_origin` ve sentetik bayraklarıyla izlenebilir kalır.
3) Model metrikleri raporlandığında, kullanılan hedef ve özelliklerin hangi bölümünün proxy olduğu açıkça belirtilir.
4) Sentetik kohort da doğrudan final model tablosuna yazılmak yerine gerçek veriyle aynı normalize ve özellik üretim zincirinden geçirilir.

Datasetin tamamı sentetik veya proxy sağlık etiketi içerdiğinden raporlanan sonuçlar klinik tanı doğruluğu veya gerçek işletme performansı iddiası taşımamaktadır.

C. Hedef Dağılımları

Bu rapordaki deney hedefi `energy_deficit_high` ikili sınıfıdır. Toplam 988 pozitif satır, datasetin yalnızca %4,52'sini oluşturmaktadır. Dolayısıyla yalnızca negatif sınıfı tahmin eden bir sistem yaklaşık %95,5 accuracy elde edebilir. Bu nedenle accuracy model seçimi için kullanılmamış, pozitif sınıf sıralama kalitesini daha iyi yansıtan PR-AUC ana metrik olarak seçilmiştir.

TABLE IX
`ENERGY_DEFICIT_HIGH` HEDEF DAĞILIMI

Sınıf	Satır	Oran
Risksiz (0)	20 852	%95,48
Yüksek risk (1)	988	%4,52

Bu hedefin sentetik üretim tanımı, ketozis veya mastitis hedeflerinden farklıdır. `energy_deficit_high`, aynı günün latent risk seviyesinden türetilir. Ketozis, mastitis, asidoz ve metritis hedefleri ise sentetik sağlık olaylarının ileri 7/14 günlük pencerede bulunmasına göre oluşturulur. Bu nedenle bu rapordaki enerji açığı sonuçları, ileri olay tahmin performansı olarak yorumlanmamalıdır.

D. Veri Kalitesi ve Kısıtlar

Veri setinde yinelenen `(cow_id, record_date)` satırı bulunmamaktadır. Sensör özelliklerinin kapsama oranı yaklaşık %99,6–100 aralığındadır. Longitudinal sentetik kol için profil, laktasyon, süt, besleme, sensör, süt trendi, etiket ve model-input tablolarının her birinde beklenen 21 600 inek-gün kaydı üretilmiştir. Ayrıca 213 günlük çevre kaydı ve ketozis, mastitis, asidoz ve metritis tiplerinde toplam 500 sentetik sağlık olayı oluşturulmuştur.

Buna karşılık en önemli kısıt, hedef etiketlerin gerçek klinik olaylardan değil sentetik/proxy üretimden gelmesidir. İleri 7/14 günlük hastalık etiketlerinin `norm_health_event` üzerinden türetilmesi hedef tanımını daha doğru hale getirse de olayların kendisi sentetiktir. Ayrıca raporlanan enerji açığı hedefi, SCC, süt bileşenleri, davranış ve bazı sensör özellikleriyle ortak bir latent risk mekanizmasından etkilenmektedir. Bu ortak üretim yapısı model başarısını iyimser gösterebilir ve özellik önemlerinin gerçek biyolojik nedensellik olarak yorumlanmasını engeller.

Ayrıca mevcut veri yükleyici, hastalık etiketi tablosuyla eşleşmeyen kayıtları ketozis, mastitis ve asidoz hedeflerinde negatif sınıfa çevirmektedir. Bu davranış eksik etiket ile doğrulanmış negatif olay arasındaki farkı gizleyebilir. Enerji açığı deneyinde hedefi eksik satırlar elendiği için ana sonuçları doğrudan etkilemez; ancak ileri-olay hastalık modelleri için takip süresi ve label coverage denetimi zorunludur.

E. Beklenen Gerçek Veri Gereksinimleri

LaktaFeed-Risk'in araştırma prototipinden operasyonel karar destek sistemine dönüşebilmesi için aşağıdaki veri gereksinimleri karşılanmalıdır:

- en az bir tam laktasyon döngüsünü kapsayan uzun dönem inek-gün geçmişi;
- süt verimiyle aynı takvimde ölçülen gerçek SCC, elektriksel iletkenlik, yağ, protein ve laktoz değerleri;
- gerçek DMI, rasyon formülü, yem reddi ve rasyon değişiklik kayıtları;

- veteriner doğrulamalı mastitis, ketozis, metritis, asidoz ve diğer klinik olay etiketleri;
- sensörlerin inek kimliği ve tarih düzeyinde süt verisiyle tam eşleşmesi;
- çiftlik, sezon ve sürü yönetimi farklılıklarını değerlendirecek çoklu kaynak veya çoklu dönem validasyon verisi.

Bu gereksinimler karşılanmadan model çıktıları, erken araştırma ve yazılım doğrulama çıktısı olarak kalmalıdır.

F. Çalıştırma Sırası ve Veri/Kod Kullanılabilirliği

Veritabanı hattı repo kökünden `00_postgresql_load_all.sql` ile tekrar üretilebilir. Bu orkestrasyon betiği sırasıyla şema ve tabloları oluşturur, meta kaynakları ekler, Proje A ve Proje B dış verilerini yükler, MmCows-proxy özelliklerini üretir ve son adımda normalize longitudinal sentetik kohortu oluşturur. Proje A eğitimi daha sonra `project_a_training_notebook.ipynb` veya `code/run_training.py` üzerinden çalıştırılır.

Kullanılan MmCows veri seti ve özgün benchmark kodu yayımlanmış bir açık veri kaynağıdır [39]. Bu çalışma kapsamında yeni bir hayvan deneyi yürütülmemiş; gözlenen kaynak kayıtları ile açıkça işaretlenmiş sentetik/proxy veriler üzerinde yazılım ve modelleme deneyi yapılmıştır. Buna karşılık mevcut Python bağımlılık listesi sürüm numaralarını sabitlememekte, notebook ana çalıştırması artifact ve ortam bilgisini otomatik kaydetmemektedir. Kesin tekrar üretilebilirlik için bağımlılık kilit dosyası, donanım/işletim sistemi özeti, veri üretim tanımı ve deney `run_id` birlikte arşivlenmelidir.

G. Deney Sonuçlarının Kapsamı

Bu rapordaki veri mimarisi ve tablo sayıları, sentetik kohortun normalize katmanlardan özellik ve etiket tablolarına taşındığı nihai veri işleme yaklaşımını tanımlamaktadır. Aşağıdaki sayısal metrikler ise raporlanan notebook çalıştırmasından elde edilen deney sonuçlarıdır. Sonuçların belirli bir veri üretim tanımıyla birebir tekrar üretilebilmesi için dataset özeti, split sayıları, model sıralaması, kalibrasyon, ablation ve tekrarlı CV çıktıları aynı `run_id` altında birlikte kaydedilmelidir.

Sentetik üretim kuralları, özellik tanımları veya etiket mantığı değiştirildiğinde tam notebook akışı yeniden çalıştırılmalı ve rapordaki sayısal sonuçlar yeni deney kaydıyla güncellenmelidir.

IV. Deneysel Sonuçlar

A. Deney Konfigürasyonu

Ana deneyde 19 ikili sınıflandırma modeli aynı ön işleme ve bölme protokolü altında çalıştırılmıştır. Test inekleri model seçiminden tamamen ayrılmış; 16 380 satır ve 102 inekten oluşan development kümesi üzerinde beş katlı inek-gruplu cross-validation uygulanmıştır. Seçim metriği CV PR-AUC ortalamasıdır. Seçilen model daha sonra development verisinin tamamında eğitilmiş ve yalnızca bir kez test kümesinde değerlendirilmiştir.

TABLE X
Ana Deney Konfigürasyonu

Alan	Değer
Hedef	`energy_deficit_high`
Toplam satır / inek	21 840 / 136
Veri üretimi	MmCows proxy + normalize sentetik kohort
Development / test	16 380 / 5 460 satır
Pozitif oran	%4,52
Model seçimi	5-fold `StratifiedGroupKFold`
Ana metrik	CV PR-AUC ortalaması
Kalibrasyon	OOF sigmoid calibration
Tekrarlı doğrulama	En iyi dört model, 5 tekrar x 5 fold

B. Model Ailelerinin Karşılaştırılması

Tablo XI, ana PR-AUC sıralamasında ilk modelleri ve farklı ailelerin en güçlü temsilcilerini göstermektedir. LDA, 0.7411 ± 0.0285 PR-AUC ile ana deneyde birinci olmuştur. Derin tabular ailesinde Torch MLP 0.7408, Torch ResNet 0.7354 ve TabNet 0.7182 değerine ulaşmıştır. Boosting ailesinde AdaBoost 0.7214, XGBoost 0.7105 ve CatBoost 0.7098 ile birbirine yakın sonuç vermiştir. Random forest 0.6995 PR-AUC üretirken, RBF-SVM ve karar ağacı sırasıyla 0.4835 ve 0.3691 ile daha zayıf kalmıştır.

Doğrusal LDA'nın karmaşık derin ve boosting modellerle aynı seviyede sonuç vermesi, mevcut sentetik tabular veri yapısında sınıflar arası ayrımın büyük ölçüde doğrusal özellik birleşimleriyle açıklanabildiğini göstermektedir. Karmaşık modellerin belirgin kazanım sağlamaması, model seçiminde yalnızca ortalama metriğin değil, hesaplama maliyeti, kalibrasyon ve açıklanabilirliğin de değerlendirilmesini gerekli kılmıştır.

C. Seçilen Modelin Test Performansı

Ana seçim metriğine göre LDA şampiyon modeldir. Test kümesinde PR-AUC 0.6927, ROC-AUC 0.9721, F1 0.6131, precision 0.5676 ve recall 0.6667 elde edilmiştir. Yüksek ROC-AUC değeri güçlü genel sıralama performansını gösterse de pozitif sınıfın azlığı nedeniyle operasyonel kaliteyi PR-AUC daha gerçekçi yansıtmaktadır. Şekil 1, recall artırıldıkça precision kaybının oluştuğunu göstermektedir.

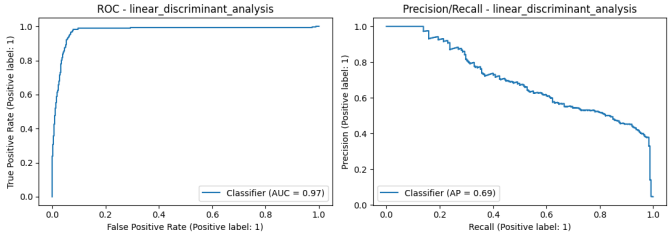


Fig. 1. Seçilen LDA modelinin test ROC ve precision-recall eğrileri.

Mevcut threshold düşük yanlış pozitif oranı karşılığında pozitif vakaların yaklaşık üçte birini kaçırmaktadır. Gerçek uygulamada kaçırılan sağlık olayının maliyeti yanlış alarm maliyetinden yüksekse threshold recall yönünde yeniden ayarlanmalıdır.

TABLE XI
ANA 5-FOLD COW-GROUP CV VE TEST SONUÇLARI

Aile	Model	CV PR-AUC	CV F1	Test PR-AUC	ROC-AUC	CV süre (sn)
Doğrusal	LDA	0.7411	0.6748	0.6927	0.9721	1.16
Derin tabular	Torch MLP	0.7408	0.6852	0.7131	0.9775	61.42
Derin tabular	Torch ResNet	0.7354	0.6789	0.6999	0.9774	81.05
Boosting	AdaBoost	0.7214	0.6762	0.7110	0.9824	119.97
Sinir ağı	sklearn MLP	0.7188	0.6625	0.7114	0.9757	14.23
Derin dikkat	TabNet	0.7182	0.6708	0.6621	0.9733	146.89
Boosting	XGBoost	0.7105	0.6682	0.7027	0.9812	3.86
Boosting	CatBoost	0.7098	0.6432	0.7060	0.9815	18.09
Boosting	Gradient Boosting	0.7070	0.6234	0.6997	0.9817	430.17
Ağaç topluluğu	Extra Trees	0.7022	0.3655	0.7128	0.9821	5.76

TABLE XII
LDA TEST CONFUSION MATRIX VE OPERASYONEL ORANLAR

Gerçek / Tahmin	Risksiz	Riskli
Gerçek risksiz	5 080	128
Gerçek riskli	84	168

Operasyonel ölçü	Değer
Yakalanan risk oranı	%66,67
Kaçırılan risk oranı	%33,33
Yanlış alarm oranı (alarmlar içinde)	%43,24
Özgüllük	%97,54

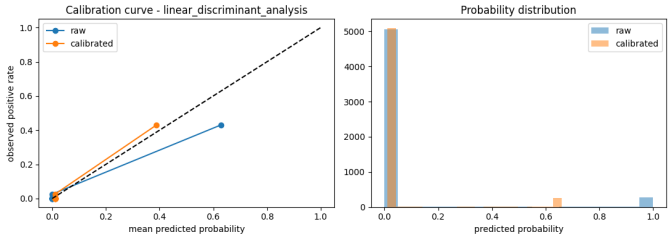


Fig. 2. LDA ham ve sigmoid-kalibre olasılıklarının test kalibrasyon eğrisi ve olasılık dağılımı.

D. Olasılık Kalibrasyonu

Karar destek sisteminde model skorunun yalnızca sıralama üretmesi değil, gerçek olay sıklığıyla uyumlu olasılık vermesi gerekir. Bu nedenle sigmoid kalibrasyon yalnızca development out-of-fold tahminleriyle eğitilmiş ve test ineklerinde değerlendirilmiştir.

TABLE XIII
LDA OLASILIK KALIBRASYONU SONUÇLARI

Küme	Olasılık	Brier	Log-loss	ECE	PR-AUC
CV OOF	Ham	0.0297	0.2188	0.0285	0.7377
CV OOF	Kalibre	0.0230	0.0906	0.0017	0.7377
Test	Ham	0.0375	0.2674	0.0365	0.6927
Test	Kalibre	0.0276	0.1048	0.0076	0.6927

Kalibrasyon test Brier skorunu %26,3, ECE değerini %79,1 ve log-loss değerini %60,8 iyileştirmiştir. PR-AUC değişmediği için örneklerin risk sıralaması korunmuştur. Şekil 2, ham LDA olasılıklarının özellikle yüksek risk bölgesinde aşırı güvenli olduğunu ve kalibrasyonun gözlenen olay oranlarına daha yakın olasılıklar ürettiğini göstermektedir.

E. SCC Ablation ve Özellik Grupları

SCC'nin etkisini ölçmek için LDA aynı inek-gruplu bölmeler üzerinde SCC dahil ve SCC hariç yeniden eğitilmiştir. SCC kaldırıldığında CV PR-AUC 0.7411'den 0.6035'e, test PR-AUC ise 0.6927'den 0.5815'e düşmüştür. Bu sonuç SCC'nin mevcut veri üretimindeki baskın sinyal olduğunu göstermektedir.

Yalnızca süt özellikleri tüm özelliklerden daha yüksek PR-AUC üretmiştir. Sensör özellikleri tek başına testte tüm özel-

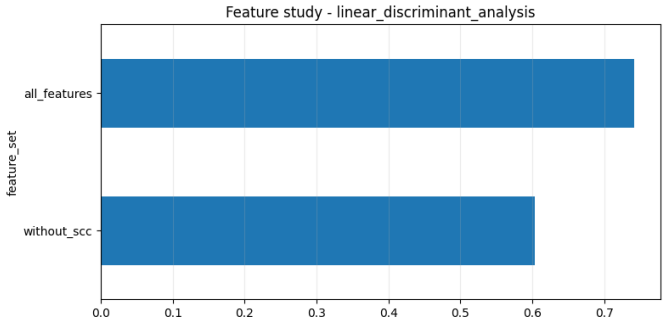


Fig. 3. SCC ablation deneyi. SCC kaldırıldığında LDA CV PR-AUC değeri 0.1376 puan düşmüştür.

TABLE XIV
ABLATION VE ÖZELLIK-GRUBU SONUÇLARI

Özellik seti	Sayı	CV PR-AUC	Test PR-AUC	Test Brier
Tüm özellikler	30	0.7411	0.6927	0.0375
SCC hariç	29	0.6035	0.5815	0.0415
Yalnızca süt	6	0.7433	0.7198	0.0345
Yalnızca sensör	13	0.7173	0.6939	0.0340
Yalnızca besleme	5	0.2199	0.2058	0.0506

liklere çok yakın bir sinyal taşırken, besleme özellikleri bu sentetik hedef için yetersiz kalmıştır. Tüm özelliklerin süt-only modelini geçememesi, bazı özelliklerin gürültü veya gereksiz tekrar eklediğini düşündürmektedir.

F. Permutation Feature Importance

Şekil 5, test setinde PR-AUC kullanılarak hesaplanan permutation importance değerlerini göstermektedir. En yüksek

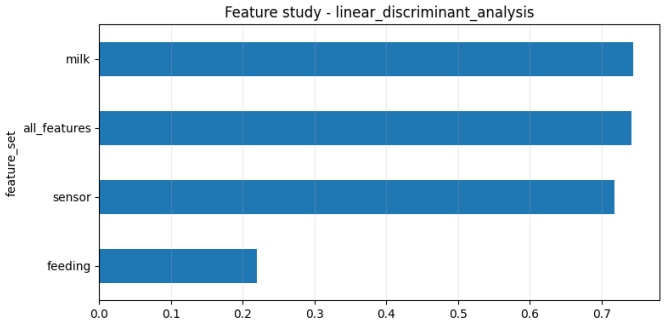


Fig. 4. Süt, sensör ve besleme özellik gruplarının tek başına LDA CV PR-AUC sonuçları.

bağımlılık SCC, yağ/protein oranı, yükseklik standart sapması, tahmini DMI ve süt protein oranında gözlenmiştir. SCC'nin önemi ablation deneyiyle tutarlıdır. Bununla birlikte SCC ve bazı sensör özellikleri sentetik latent risk mekanizmasından üretildiğinden bu sıralama biyolojik nedensellik olarak yorumlanmamalıdır.

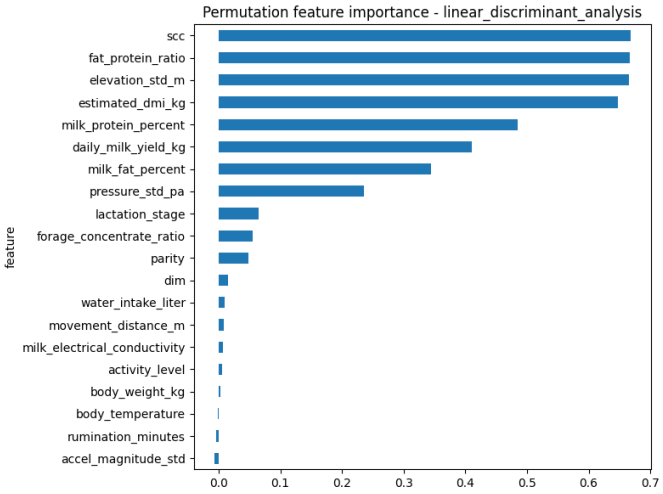


Fig. 5. Seçilen LDA modelinin test permutation feature importance sonuçları.

G. Tekrarlı En İyi-Dört Model Doğrulaması

Ana deneydeki ilk dört model, beş farklı random seed ve beş fold ile toplam 25 validation sonucu üzerinde yeniden değerlendirilmiştir.

TABLE XV
EN İYI DÖRT MODEL IÇIN 5 TEKRAR X 5 FOLD COW-GROUP CV

Model	PR-AUC	Std.	F1	Brier	Süre (sn)
Torch ResNet	0.7341	0.0582	0.6833	0.0482	463.25
LDA	0.7331	0.0550	0.6741	0.0296	5.21
Torch MLP	0.7324	0.0611	0.6800	0.0471	448.94
AdaBoost	0.7236	0.0576	0.6806	0.0726	726.66

Torch ResNet ile LDA arasındaki ortalama PR-AUC farkı yalnızca 0.0010 olup yaklaşık 0.055 standart sapmanın çok altındadır. Şekil 6 üzerindeki kutuların büyük ölçüde örtüşmesi, dört modelin fold ve inek seçimine bağlı değişkenliğinin modeller arası ortalama farklardan daha büyük olduğunu göstermektedir. LDA, Torch ResNet ile pratikte eşit PR-AUC sunarken daha düşük Brier skoru ve yaklaşık 89 kat daha kısa CV süresi sağlamıştır.

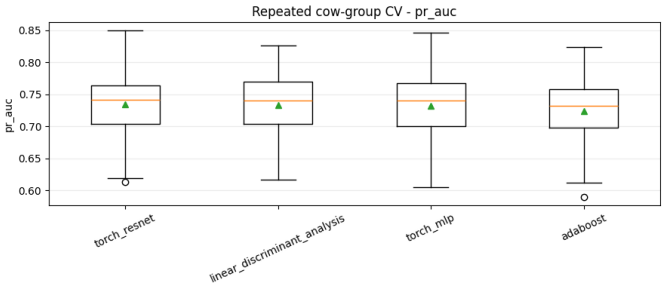


Fig. 6. En iyi dört modelin 25 fold üzerindeki PR-AUC dağılımı.

V. TARTIŞMA

A. Model Ailelerinin Sonuçlarının Yorumu

Deneyler, karmaşık model ailesinin otomatik olarak daha iyi sonuç vermediğini göstermektedir. Doğrusal LDA hem ana beş-fold seçiminde birinci olmuş hem de tekrarlı CV'de Torch ResNet ile pratikte eşit kalmıştır. Bu sonuç, mevcut tabular özelliklerin ve raporlanan `energy_deficit_high` hedefini üreten sentetik latent-risk mekanizmasının büyük ölçüde doğrusal bir ayrım oluşturduğuna işaret etmektedir. Logistic regression benzer F1 üretmesine rağmen PR-AUC açısından LDA'nın gerisinde kalmıştır; LDA'nın ortak kovaryans yapısını kullanması bu veri üzerinde avantaj sağlamıştır.

Derin tabular modeller güçlü sonuç vermiş, ancak hesaplama maliyetleri karşılığında tekrarlı doğrulama değişkenliğini aşan belirgin bir PR-AUC artışı sağlamamıştır. Torch MLP ana beş-fold deneyinde LDA'ya en yakın derin model, Torch ResNet ise tekrarlı doğrulamada en yüksek ortalamaya sahip model olmuştur. TabNet'in CV ve test PR-AUC değerleri diğer iki derin modelin gerisinde kalmıştır. Boosting ailesinde AdaBoost, XGBoost ve CatBoost benzer sıralama kalitesi göstermiştir. AdaBoost'un olasılık kalitesi ve eğitim maliyeti LDA'dan belirgin biçimde daha kötüdür. Ağaç toplulukları ve kernel/instance tabanlı modeller ise mevcut özellik geometrisi üzerinde ilk modellerin gerisinde kalmıştır.

B. Model Seçim Kararı

LDA mevcut champion model olarak seçilmiştir. Bu karar yalnızca ana CV PR-AUC birinciliğine değil, aşağıdaki bileşik gerekçelere dayanmaktadır:

- Torch ResNet ile pratikte eşit tekrarlı CV PR-AUC;
- top-4 modeller içindeki en düşük Brier skoru;
- sigmoid kalibrasyon sonrasında güçlü olasılık kalitesi;
- derin ve boosting modellere göre çok daha düşük eğitim maliyeti;
- katsayı tabanlı ve denetlenebilir model yapısı.

LaktaFeed-Opt tarafına aktarılacak skorlar ham LDA olasılığı yerine kalibre edilmiş olasılık olmalıdır.

C. Geçerlilik Tehditleri

En önemli tehdit, tüm sağlık hedeflerinin sentetik/proxy olmasıdır. Veri hattı sentetik hastalık etiketlerini ileri 7/14 günlük olay penceresiyle oluştursa da bu olaylar gerçek veteriner tanısı değildir. Bu raporda kullanılan `energy_deficit_high` hedefi ise aynı gün üretilen sentetik latent risk seviyesinden gelir. SCC, bazı süt bileşenleri ve sensör özellikleri ile bu hedef aynı latent mekanizmadan etkilenmektedir. SCC ablation sonucundaki büyük performans kaybı modelin bu sentetik ortak yapıya bağımlılığını açıkça göstermektedir. Dolayısıyla yüksek ROC-AUC veya PR-AUC değerleri gerçek biyolojik genelleme kanıtı değildir. Test inekleri model seçiminden ayrı tutulmuş olsa da test kümesi de aynı sentetik üretim sürecinden gelmektedir. Farklı çiftlik, dönem, sensör cihazı veya gerçek klinik olay üzerinde external validation yapılmamıştır.

D. Uygulama ve İnsan Denetimi

LaktaFeed-Risk çıktısı otomatik tanı değil, veteriner ve besleme uzmanının inceleme önceliğini destekleyen erken uyarı sinyalidir. Mevcut threshold ile risklerin %33,33'ü kaçırılmakta ve üretilen alarmların %43,24'ü yanlış alarm olmaktadır. Gerçek uygulamada threshold; kaçırılan sağlık olayının maliyeti, yanlış alarm inceleme maliyeti ve uzman kapasitesiyle birlikte belirlenmelidir. İnsan-AI etkileşimi ve güvenlik sınırlarının açık raporlanması DECIDE-AI yaklaşımıyla da uyumludur [32].

E. Gelecek Çalışma

Sonraki aşamada gerçek SCC, süt bileşenleri, DMI, rasyon tüketimi ve veteriner doğrulamalı klinik olaylar aynı inek-gün takviminde toplanmalıdır. Gerçek veri geldiğinde SCC ablation ve özellik-grubu deneyleri tekrarlanmalı; çiftlik, sezon ve recent-cohort holdout ile external validation yapılmalıdır. Ayrıca kalibre edilmiş LDA skorlarını `feat_prediction_a` tablosuna yazan çıkarım katmanı tamamlanmalı ve LaktaFeed-Opt üzerindeki rasyon maliyeti, beklenen süt geliri ve sağlık penalty etkisi ölçülmelidir. Yeterli longitudinal gerçek veri oluştuğunda 7/14/30 günlük pencere özellikleri ve ayrı bir sequence pipeline üzerinden LSTM veya temporal Transformer modelleri değerlendirilebilir.

Veri hattı açısından sonraki mühendislik adımı, normalize sentetik kohort üretim yolunun gerçek çiftlik verisi geldiğinde aynı normalize ve özellik tablolarını yeniden üretebilmesini otomatik regresyon testleriyle güvenceye almaktır. Her veri üretim tanımı değişikliğinden sonra notebook metrikleri yeniden çalıştırılmalı ve rapordaki sonuç tabloları yeni `run_id` ile eşleştirilmelidir.

VI. Sonuç

Bu çalışma, LaktaFeed-Risk için veri mühendisliği, çok-aileli model registry, inek-gruplu cross-validation, olasılık kalibrasyonu, açıklanabilirlik ve ablation deneylerini birleştiren tekrar üretilebilir bir makine öğrenmesi altyapısı sunmuştur. Veri hattı, ham MmCows kayıtlarını koruyup proxy tamamlama yaparken, bağımsız longitudinal sentetik kohortu önce normalize katmanlara sonra model-ready feature/label tablolarına dönüştürmektedir. Ana deneyde LDA 0.7411 ± 0.0285 CV PR-AUC ve 0.6927 test PR-AUC ile seçilmiştir. Tekrarlı doğrulamada Torch ResNet ile LDA arasında pratik açıdan belirgin bir fark gözlenmemiş; LDA daha iyi olasılık kalitesi, açıklanabilirlik ve hesaplama verimliliği nedeniyle champion model olarak korunmuştur. Sigmoid kalibrasyon Brier score, log-loss ve ECE değerlerini belirgin biçimde iyileştirmiştir. SCC ablation ve özellik-grubu deneyleri, mevcut sentetik/proxy veride süt özelliklerinin baskın olduğunu göstermiştir. Bu sonuçlar çalışır bir karar destek prototipini doğrulamaktadır; ancak gerçek klinik etiketlerle bağımsız doğrulama yapılmadan üretim veya klinik başarı iddiası taşımamaktadır. Veri üretim veya etiket tanımı değiştirildiğinde metriklerin yeniden üretilmesi gerekmektedir.

References

[1] "Machine learning-based prediction of clinical mastitis in dairy cows: A comparative analysis of 9 algorithms using production and management data," PubMed record, 2025, accessed: 2026-06-05. [Online]. Available: https://pubmed.ncbi.nlm.nih.gov/41397607/

[2] "Time series data analysis to predict the status of mastitis in dairy cows by applying machine learning models to automated milking systems data," PubMed record, 2025, accessed: 2026-06-05. [Online]. Available: https://pubmed.ncbi.nlm.nih.gov/40466393/

[3] "Research on the prediction model of mastitis in dairy cows based on time series characteristics," PubMed record, 2025, accessed: 2026-06-05. [Online]. Available: https://pubmed.ncbi.nlm.nih.gov/40343367/

[4] "The prediction of clinical mastitis in dairy cows based on milk yield, rumination time, and milk electrical conductivity using machine learning algorithms," *Animals*, 2024. [Online]. Available: https://pmc.ncbi.nlm.nih.gov/articles/PMC10854744/

[5] "Predicting subclinical ketosis in dairy cows using machine learning techniques," *Animals*, 2021. [Online]. Available: https://pmc.ncbi.nlm.nih.gov/articles/PMC8300340/

[6] "Comparison of machine learning methods to predict udder health status based on somatic cell counts in dairy cows," *Scientific Reports*, 2021. [Online]. Available: https://www.nature.com/articles/s41598-021-93056-4

[7] "Supervised machine learning approaches for early detection of metabolic and udder health disorders in dairy cows using sensor-derived data," *Frontiers in Veterinary Science*, 2025. [Online]. Available: https://www.frontiersin.org/journals/veterinary-science/articles/10.3389/fvets.2025.1726719/abstract

[8] National Academies of Sciences, Engineering, and Medicine, *Nutrient Requirements of Dairy Cattle: Eighth Revised Edition*. The National Academies Press, 2021. [Online]. Available: https://www.ncbi.nlm.nih.gov/books/NBK600610/

[9] University of Minnesota Extension, "Formulating dairy cow rations," accessed: 2026-06-05. [Online]. Available: https://extension.umn.edu/dairy-milking-cows/formulating-dairy-cow-rations

[10] University of Wisconsin Extension, "Body condition score in dairy cattle," accessed: 2026-06-05. [Online]. Available: https://dairy.extension.wisc.edu/articles/body-condition-score-in-dairy-cattle/

[11] Food and Agriculture Organization of the United Nations, "Milk production," Gateway to dairy production and products, accessed: 2026-06-05. [Online]. Available: https://www.fao.org/dairy-production-products/production/milk-production/

[12] World Bank, "Moving towards sustainability: The livestock sector and the world bank," 2021, accessed: 2026-06-05. [Online]. Available: https://www.worldbank.org/en/topic/agriculture/brief/moving-towards-sustainability-the-livestock-sector-and-the-world-bank

[13] R. García, J. Aguilar, M. Toro, A. Pinto, and P. Rodríguez, "A systematic literature review on the use of machine learning in precision livestock farming," *Computers and Electronics in Agriculture*, vol. 179, p. 105826, 2020. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0168169920317099

[14] D. Lovarelli, J. Bacenetti, and M. Guarino, "A review on dairy cattle farming: Is precision livestock farming the compromise for an environmental, economic and social sustainable production?" *Journal of Cleaner Production*, vol. 262, p. 121409, 2020. [Online]. Available: https://www.sciencedirect.com/science/article/abs/pii/S0959652620314566

[15] World Organisation for Animal Health, "Chapter 7.11. animal welfare and dairy cattle production systems," Terrestrial Animal Health Code, 2022, accessed: 2026-06-05. [Online]. Available: https://www.oie.int/fileadmin/Home/eng/Health_standards/tahc/current/chapitre_aw_dairy_cattle.pdf

[16] P. Rasmussen, H. W. Barkema, P. P. Osei, J. Taylor, A. P. Shaw, B. Conrady, G. Chaters, V. Muñoz-Gómez, D. C. Hall, O. O. Apenteng, J. Rushton, and P. R. Torgerson, "Global losses due to dairy cattle diseases: A comorbidity-adjusted economic analysis," *Journal of Dairy Science*, vol. 107, no. 9, pp. 6945–6970, 2024. [Online]. Available: https://pmc.ncbi.nlm.nih.gov/articles/PMC11382338/

[17] P. Stanek, P. Zołkiewski, and E. Januś, "A review on mastitis in dairy cows research: Current status and future perspectives," *Agriculture*, vol. 14, no. 8, p. 1292, 2024. [Online]. Available: https://www.mdpi.com/2077-0472/14/8/1292

[18] K. Dolecheck and J. Bewley, "Animal board invited review: Dairy cow lameness expenditures, losses and total cost," *Animal*, vol. 12, no. 7, pp. 1462–1474, 2018. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1751731118000575

[19] United Nations Department of Economic and Social Affairs, "Goal 2: End hunger, achieve food security and improved nutrition and promote sustainable agriculture," 2025, accessed: 2026-06-05. [Online]. Available: https://sdgs.un.org/goals/goal2

[20] Food and Agriculture Organization of the United Nations, "Milk and dairy hold potential for improving nutrition of world's poor," 2013, accessed: 2026-06-05. [Online]. Available: https://www.fao.org/newsroom/detail/Milk-and-dairy-hold-potential-for-improving-nutrition-of-world-s-poor/en

[21] ——, "Social and gender issues," Gateway to dairy production and products, accessed: 2026-06-05. [Online]. Available: https://www.fao.org/dairy-production-products/socio-economics/social-and-gender-issues/en/

[22] United Nations Department of Economic and Social Affairs, "Goal 1: End poverty in all its forms everywhere," 2025, accessed: 2026-06-05. [Online]. Available: https://sdgs.un.org/goals/goal1

[23] ——, "Goal 5: Achieve gender equality and empower all women and girls," 2025, accessed: 2026-06-05. [Online]. Available: https://sdgs.un.org/goals/goal5

[24] ——, "Goal 8: Promote sustained, inclusive and sustainable economic growth, full and productive employment and decent work for all," 2025, accessed: 2026-06-05. [Online]. Available: https://sdgs.un.org/goals/goal8

[25] Food and Agriculture Organization of the United Nations, "Livestock solutions for climate change," 2017, accessed: 2026-06-05. [Online]. Available: https://www.fao.org/family-farming/detail/en/c/1634679/

[26] United Nations Department of Economic and Social Affairs, "Goal 12: Ensure sustainable consumption and production patterns," 2025, accessed: 2026-06-05. [Online]. Available: https://sdgs.un.org/goals/goal12

[27] ——, "Goal 13: Take urgent action to combat climate change and its impacts," 2025, accessed: 2026-06-05. [Online]. Available: https://sdgs.un.org/goals/goal13

[28] World Health Organization, "Antimicrobial resistance," Fact sheet, 2025, accessed: 2026-06-05. [Online]. Available: https://www.who.int/news-room/fact-sheets/detail/antimicrobial-resistance

[29] Food and Agriculture Organization of the United Nations, "How to use antibiotics effectively and responsibly in dairy production: For the sake of human and animal health," 2021, accessed: 2026-06-05. [Online]. Available: https://www.fao.org/family-farming/detail/en/c/1755273/

[30] "Tripod+ai statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods," *BMJ*, vol. 385, 2024. [Online]. Available: https://www.bmj.com/content/385/bmj-2023-078378

[31] "Probast+ai: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods," *BMJ*, vol. 388, 2025. [Online]. Available: https://www.bmj.com/content/388/bmj-2024-082505

[32] "Reporting guideline for the early-stage clinical evaluation of decision support systems driven by artificial intelligence: Decide-ai," *Nature Medicine*, vol. 28, pp. 924–933, 2022. [Online]. Available: https://www.nature.com/articles/s41591-022-01772-9

[33] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, pp. 273–297, 1995. [Online]. Available: https://link.springer.com/article/10.1007/BF00994018

[34] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. [Online]. Available: https://www.ovid.com/journals/male/fulltext/00010134-200145010-00001~random-forests

[35] T. Chen and C. Guestrin, "Xgboost: A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794. [Online]. Available: https://arxiv.org/abs/1603.02754

[36] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "Lightgbm: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems*, 2017. [Online]. Available: https://papers.nips.cc/paper/6907-lightgbm-a-highly-efficient-gradient-boosting-decision-tree.pdf

[37] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, and A. Gulin, "Catboost: Unbiased boosting with categorical features," in *Advances in Neural Information Processing Systems*, 2018. [Online]. Available: https://arxiv.org/abs/1706.09516

[38] Y. Gorishniy, I. Rubachev, V. Khrulkov, and A. Babenko, "Revisiting deep learning models for tabular data," in *Advances in Neural Information Processing Systems*, 2021. [Online]. Available: https://arxiv.org/abs/2106.11959

[39] H. Vu, O. Prabhune, U. Raskar, D. Panditharatne, H. Chung, C. Y. Choi, and Y. Kim, "Mmcows: A multimodal dataset for dairy cattle monitoring," in *Advances in Neural Information Processing Systems*, vol. 37, 2024, pp. 59 451–59 467.