Süt Sığırcılığında İnek Bazında Elde Tutma/Sürüden Çıkarma Kararı için Model-Free Pekiştirmeli Öğrenme: Empirik Stokastik Bir MDP Üzerinde Q-Learning ve DQN'in Karşılaştırmalı Değerlendirmesi

Artun Kara (255172008)
Bilişim Sistemleri Mühendisliği
Kocaeli, Türkiye
artunankara@gmail.com

***Abstract*—Süt sığırcılığında her inek için aylık olarak verilen *elde tutma (keep)* veya *sürüden çıkarma (cull)* kararı; ardışık, ödülü gecikmeli ve dinamiği belirsiz bir sıralı karar problemidir. Bu çalışmada, gerçek hayvan kayıtlarından kestirilen *empirik ve stokastik* bir Markov Karar Süreci (MDP) ortamı kurulmuş ve karar politikası, modeli bilmeyen (*model-free*) iki pekiştirmeli öğrenme (RL) ajanıyla öğrenilmiştir: tablo tabanlı Q-Learning ve derin Q-ağı (Stable-Baselines3 DQN). Ödül, ABD 2025 ekonomik parametrelerinden türetilen ve kodla birebir eşleşen bir aylık kar fonksiyonudur. Ajanlar; rastgele, keep-all, cull-all ve risk-eşiği temel politikalarıyla (baseline) ve modeli bilen değer iterasyonu (value iteration, VI) optimumuyla, beş tohum (seed) üzerinde ortalama±standart sapma bandıyla karşılaştırılmıştır. Tam ölçekli koşuda Q-Learning -204, DQN -270 USD ortalama episode getirisi elde ederek tüm baseline'ları belirgin biçimde geçmiş; Q-Learning, model tabanlı VI optimumuyla (-225) istatistiksel olarak eşitlenmiştir (fark anlamlı değildir). Tüm sonuçlar ≥ 5 tohum üzerinde tekrarlanabilir, ham loglardan doğrulanabilir ve tek komutla yeniden üretilebilir.**

***Anahtar Kelimeler*—pekiştirmeli öğrenme, Markov karar süreci, Q-learning, DQN, model-free, sürü yönetimi, keep/cull, stokastik ortam**

I. Giriş

Süt sığırcılığı işletmelerinde sürü kompozisyonu, işletme kârlılığının en güçlü belirleyicilerinden biridir. Bir ineğin sürüde tutulması; gelecekteki süt geliriyle, artan hastalık ve üreme riskinin getirdiği maliyetler arasında bir denge gerektirir. Bir ineğin sürüden çıkarılması ise anlık bir karkas/satış geliri sağlar, ancak yerine yüksek maliyetli bir düve (replacement) konmasını zorunlu kılar. Bu karar tek seferlik değildir: her ay, her hayvan için yeniden verilir ve bugünkü karar, hayvanın gelecekteki durumunu ve dolayısıyla gelecekteki getiriyi doğrudan etkiler.

Bu rapor, problemi sıralı bir karar süreci olarak ele alır ve şu katkıları sunar: (i) gerçek hayvan kayıtlarından kestirilen, geçişleri stokastik bir keep/cull MDP ortamı; (ii) ekonomik parametrelerden türetilen ve kaynak kodla *birebir* eşleşen bir ödül mekanizması; (iii) iki model-free RL ajanının (tablo Q-Learning ve derin DQN) çok-tohumlu, baseline ve model-tabanlı optimumla karşılaştırmalı değerlendirmesi; (iv) tamamen tekrarlanabilir, ham loglardan doğrulanabilir bir deney hattı. Çalışmanın hedefi, okuyucunun problemin neden RL gerektirdiğini, ortamın nasıl kurulduğunu, ödülün neyi optimize ettiğini ve hangi yöntemin neden seçildiğini eksiksiz anlamasıdır.

A. İlgili Çalışmalar

İnek değiştirme (cow replacement) problemi, harekât araştırmasında onlarca yıldır dinamik programlama (DP) ve Markov karar süreçleriyle incelenmiştir; Kristensen'in hiyerarşik Markov süreçleri [6] ve Cabrera'nın ekonomik replacement modelleri [7] bu geleneğin temsilcileridir. Bu klasik çalışmalar geçiş ve verim dağılımlarını çoğunlukla *varsayımsal parametrik* biçimde alıp modeli bilen DP ile çözer. Bu çalışmanın ayırt edici yanı; geçişleri *gerçek aylık kayıtlardan empirik* kestirmesi, kararı *model-free* RL (Q-Learning, DQN) ile öğrenmesi, denetimli bir culling-risk skorunu duruma katması ve sonuçları ≥ 5 tohumla tekrarlanabilir biçimde raporlamasıdır. Genel iş akışı Şekil 1'de özetlenmiştir.

II. Arka Plan ve Neden Pekiştirmeli Öğrenme?

A. Markov Karar Süreci

Problem $\langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$ beşlisiyle modellenir: $\mathcal{S}$ durum kümesi, $\mathcal{A} = \{\text{keep}, \text{cull}\}$ aksiyon kümesi, $P(s' \mid s, a)$ geçiş olasılığı, $R(s, a)$ ödül ve $\gamma = 0.97$ iskonto faktörüdür.

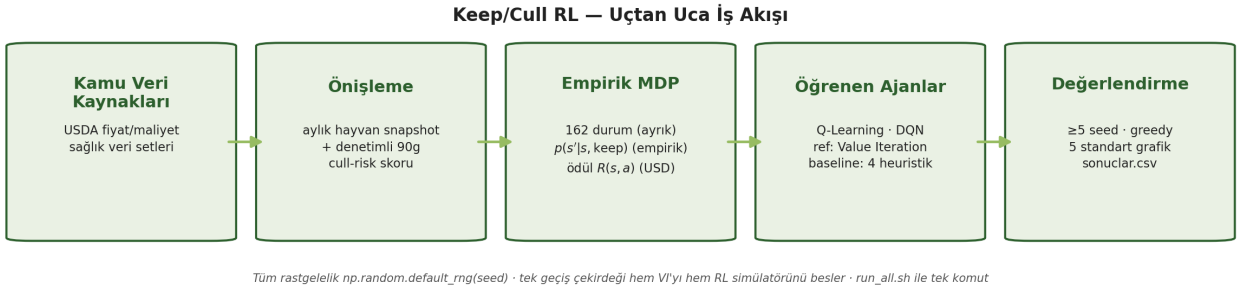


Fig. 1. Uçtan uca iş akışı: kamu verisi → aylık snapshot ve denetimli risk skoru → empirik stokastik MDP (durum/geçiş/ödül) → model-free ajanlar (VI referans, heuristik baseline) → çok-tohumlu değerlendirme.

Amaç, beklenen iskontolu getiriyi $\mathbb{E}\big[\sum_t \gamma^t R(s_t, a_t)\big]$ en-büyükleyen bir $\pi(a \mid s)$ politikasıdır.

B. Neden RL? (zorunlu gerekçe)

Problemin RL gerektirdiği dört ölçütle gösterilir:

- **Ardışıklık:** `keep` aksiyonu hayvanı bir sonraki aylık duruma taşır (laktasyon ilerler, verim ve risk değişir); karar geleceği etkiler.
- **Gecikmeli ödül:** Tutmanın değeri, gelecekteki süt gelirinden birikmiş sağlık/üreme riskinin çıkarılmasıdır; bu ancak ileride gerçekleşir.
- **Belirsiz dinamik ve büyük uzay:** Geçiş kuralı analitik değil, gerçek kayıtlardan empirik olarak kestirilmiştir; 162 ayrık durum ve stokastik geçişler içerir.
- **Daha ucuz alternatif yok:** Ortam stokastik olduğundan (Bölüm III-D) A*/BFS gibi tek-hedefli en kısa yol yöntemleri uygulanamaz; basit risk-eşiği kuralı denenmiş ve RL ajanlarının gerisinde kalmıştır.

Ortam statik/deterministik küçük bir ızgara değildir; bu nedenle baseline karşılaştırması zorunlu olmamakla birlikte RL kazancını ölçmek için dahil edilmiştir.

C. Neden Model-Free?

Çalışmada modeli bilen bir referans (value iteration) bilinçli olarak tutulmuştur; ancak teslim edilen *öğrenen* ajanlar model-free'dir. Üç gerekçe öne çıkar. Birincisi, dersin amacı öğrenmeyi (öğrenme/eval eğrileri, keşif–sömürü dengesi) göstermektir; model-free ajanlar bu dinamiği doğrudan üretir. İkincisi, model-free yöntemler karar anında tam geçiş modeline ihtiyaç duymadan örneklenmiş etkileşimden öğrenir; bu, modelin bilinmediği veya çok büyük olduğu gerçek dünya koşullarına genelleşir. Üçüncüsü, model-free Q-Learning bu ortamda model-tabanlı VI optimumuna istatistiksel olarak eşitlenmiştir (Bölüm VI); aradaki fark, sonlu-örneklem Monte-Carlo değerlendirme gürültüsü içindedir (eşli t-testi $p \approx 0.37$; bir tohumda VI öndedir). VI, simülatörle aynı geçiş çekirdeğinin optimumu olduğundan gerçek tavandır; bu sonuç, modeli hiç kullanmayan bir ajanın geçiş modelini bilmeden model-tabanlı optimuma ulaşabildiğini gösterir.

III. Ortam ve MDP Formülasyonu

A. Durum (State)

Her hayvan-ay snapshot'ı, aşağıdaki bileşenlerin ayrıklaştırılmasıyla bir *durum kovasına* (`state_bucket_exact`) eşlenir: laktasyon evresi, parite grubu, DIM (laktasyon günü) bandı, süt seviyesi bandı, süt trendi bandı, sağlık risk bandı ve denetimli modelden gelen 90 günlük culling-risk bandı. Bu ayrıklaştırma 162 ulaşılabilir durum üretir. Süt trendi ve risk bandı gibi bileşenler, geçmiş bilgisinin bir özetini duruma taşıyarak Markov varsayımını güçlendirir.

B. Aksiyon (Action)

Aksiyon uzayı iki ayrık seçenekten oluşur: `keep` (0, terminal değil) ve `cull` (1, terminal). Gymnasium ortamında bu `spaces.Discrete(2)` ile tanımlıdır.

C. Ödül Mekanizması (kod ile birebir)

Ödül, bir aylık net ekonomik kârı temsil eder. Parametreler `reward_baseline_us_2025.csv` dosyasından gelir; süt fiyatı ve bakım maliyeti USDA 2025 kaynaklıdır, kalan dört parametre prototip varsayımıdır (Bölüm VIII). **Keep** ödülü, ineği bir ay daha tutmanın net getirisini modeller: süt geliri eksi bakım, sağlık riski, üreme riski ve beklenen culling riski maliyetleri (kaynak: `kod/env/rl_mdp_utils.py:120`):

$$R_{\text{keep}}(s) = \underbrace{m\,d\,p}_{\text{süt geliri}} - \underbrace{c_b\,d}_{\text{bakım}} - C_{\text{sağlık}} - C_{\text{üreme}} - C_{\text{bek-cull}} \quad (1)$$

$$C_{\text{sağlık}} = c_t\big(\tfrac{1}{3} n_h + 0.25\,\mathbf{1}_{\text{mast}} + 0.25\,\mathbf{1}_{\text{top}} + 0.15\,\mathbf{1}_{\text{hücre}}\big) \quad (2)$$

$$C_{\text{üreme}} = c_i \max(n_s - 2, 0) + c_i\,\mathbf{1}_{[\text{gebe}<0.5\,\wedge\,\text{DIM}>150]} \quad (3)$$

$$C_{\text{bek-cull}} = 0.25\; p_{\text{cull}}^{30}\; c_r \quad (4)$$

Cull ödülü, hayvanı bugün çıkarmanın net getirisidir: karkas/satış değeri eksi düve maliyeti (kaynak: `kod/env/rl_mdp_utils.py:76`):

$$R_{\text{cull}}(s) = v_c - c_r - c_{\text{disp}}, \qquad c_{\text{disp}} = 0 \quad (5)$$

Sezgisel olarak: R_{keep} yüksek sütlü, sağlıklı, düşük riskli ineklerde pozitife yaklaşır; risk ve maliyet biriktikçe küçülür.

TABLE I
Ödül sembolleri, değerleri ve kaynak kod satırları.

Sembol	Anlam	Değer	Kod (`rl_mdp_utils.py`)
m	günlük süt (kg)	durum	`:89-90`
d	ay/gün	30.4375	`config: days_in_month`
p	süt fiyatı	0.4668	`:90`
c_b	günlük bakım	8.5337	`:91`
c_t	tedavi	150	`:96-105`
c_i	tohumlama	35	`:109-113`
c_r	replacement	2500	`:115-119, 76`
v_c	cull satışı	1200	`:76`
p^{30}_{cull}	30g risk (denetimli)	—	`:115-119`

R_{cull} ise sabit bir taban getiridir ($v_c - c_r$). Ajan, bu iki getirinin *gelecekteki* sonuçlarını iskontolayarak karşılaştırmayı öğrenir. Sembollerin değer ve kod karşılıkları Tablo I'de verilmiştir; rapordaki LaTeX ile kod birebir aynıdır.

Sayısal örnek. Sağlıklı, yüksek verimli bir inek ($m =$ 35 kg, sağlık olayı yok, gebe, DIM= 80, $p^{30}_{\text{cull}} = 0.05$) için $R_{\text{keep}} = 497.3 - 259.7 - 31.3 = +206.3$ USD iken aynı ay $R_{\text{cull}} = 1200 - 2500 = -1300$ USD'dir: tutmak açıkça baskındır. Buna karşın düşük verimli, hasta bir inek ($m = 12$, mastitis ve topallık, $n_h = 3$, açık, DIM= 200, servis= 4, $p^{30}_{\text{cull}} = 0.40$) için $R_{\text{keep}} = 170.5 - 259.7 - 225 - 105 - 250 = -669.2$ USD olur; bu anlık değer hâlâ cull tabanından (-1300) iyidir. Ancak böyle bir hayvanı tutmak ardışık olarak daha kötü durumlara yol açar ve bu kötü ayların *iskontolu toplamı* tek seferlik -1300'ün altına inebilir; ajan, tam da bu *gelecek* hesabı yüzünden bazı durumlarda cull'u seçer. Bu, cull'un nadiren anlık olarak yeterli olduğunu fakat değerinin gelecekteki trajektoriden geldiğini gösterir.

D. Geçiş: Stokastik ve Empirik

`keep` aksiyonundan sonraki durum, gerçek kayıt frekanslarından kurulan empirik bir dağılımdan örneklenir (kaynak: `kod/env/rl_experiment_utils.py:161`):

```
selected = outcomes[int(
    rng.choice(len(outcomes), p=probabilities))]
```

162 durumun 120'sinde (%74) `keep` altında birden çok olası s' vardır; örneğin bir başlangıç durumu üç farklı sonraki duruma her biri $p = 0.333$ olasılıkla geçer. Bu, ortamın *tanım gereği stokastik* olduğunu kanıtlar. `cull` ise deterministik terminaldir. Tüm rastgelelik `np.random.default_rng(seed)` ile yönetilir; eski Gym API'si ve `np.random.seed/choice` kullanılmaz.

Modelin kuruluşu. Empirik geçiş modeli, aynı hayvanın ardışık aylık snapshot'ları arasındaki gözlenen (s, keep, s') geçişleri sayılarak kurulur; olasılık basit göreli frekanstır (`count/total_count`, düzleştirme yok). Bir durumun tam-kova desteği eşiğin altındaysa (< 5), tahmin seyreklikten gürültülenmesin diye model daha kaba kovalara *geri-düşer* (exact → risk'siz → evre+parite → global). Kritik olarak bu *tek* geçiş çekirdeği hem değer iterasyonunu hem de RL simülatörünü besler; dolayısıyla

TABLE II
Yöntemler ve rolleri.

Yöntem	Tür	Rol
Tablo Q-Learning	model-free, off-policy	Ana ajan
SB3 DQN	model-free, off-policy, replay	Ana ajan (derin)
Value Iteration	model-based exact	Optimum referans
keep/cull/random/risk	heuristik	Baseline

VI ile ajanlar arasında bir model uyuşmazlığı yoktur ve Bölüm VI'teki karşılaştırma aynı dinamik üzerinde adildir.

IV. Yöntemler

Tablo II dört yaklaşımı özetler. *Öğrenen* ajanlar model-free'dir; VI optimum referans (tavan), heuristikler ise baseline'dır.

Tablo Q-Learning (off-policy). Davranış politikası ε-greedy'dir (`kod/rl_core.py:309`); güncelleme hedefi ise açgözlü $r + \gamma \max_{a'} Q(s', a')$'dir (`:321`). Veriyi üreten politika ile iyileştirilen politikanın farklı olması, yöntemi off-policy yapar. SARSA'dan tek satırlık farkı, hedefte davranışın seçtiği a' yerine $\max_{a'}$ kullanılmasıdır.

SB3 DQN (off-policy, derin). Gözlem, durum metadata'sından kurulan yoğun bir sayısal vektördür (one-hot + z-normalizasyon). DQN bir *replay buffer* (`kod/rl_core.py:474`) ve hedef ağ kullanır; tekrar arabelleği, geçmiş politikaların ürettiği geçişleri yeniden kullandığından yöntem tanımı gereği off-policy'dir.

Value Iteration empirik geçiş ve ödül tablolarından Bellman optimal denklemini çözerek tavan referansı verir. **Baseline'lar** eğitimsizdir: `keep_all`, `cull_all`, `random` ($p_{\text{cull}} = 0.05$) ve risk-eşiği ($p^{90}_{\text{cull}} \geq 0.35$).

V. Deneysel Kurulum

Tüm eğitim ve değerlendirme beş tohum üzerinde tekrarlanır: $\{42, 123, 2024, 7, 99\}$ (≥ 5). `full` profilinde DQN 100k adım, Q-Learning 4000 episode boyunca eğitilir; iskonto $\gamma = 0.97$, VI yakınsama toleransı 10^{-4}. Değerlendirme *deterministik/açgözlü* politikayla, tohum başına 500 episode koşularak yapılır; ortam stokastik olduğundan her değerlendirme bir dağılımdır. Tekrarlanabilirlik için bağımlılıklar `==` ile sabitlenmiş, rastgelelik tohumlanmış ve tüm hat tek komutla (`run_all.sh`) üretilebilir kılınmıştır. Raporda anlatılan her deneyin ham logu `sonuclar/loglar/` altında bulunur ve grafikler bu loglardan doğrulanabilir. Eğitim hiperparametreleri Tablo III'de toplanmıştır.

VI. Bulgular ve Tartışma

Tablo IV, beş tohum üzerinde ortalama±standart sapma getirileri özetler. Her iki ajan da tüm baseline'ları belirgin biçimde geçmiştir. DQN tohumlar arasında oldukça kararlıdır (std 20). Q-Learning'in ortalama getirisi (-204), VI optimumuyla (-225) istatistiksel olarak

TABLE III
EĞITIM HIPERPARAMETRELERI (FULL PROFIL).

Parametre	Q-Learning	DQN
İskonto γ	0.97	0.97
Eğitim bütçesi	4000 episode	100k adım
Öğrenme oranı	$\alpha = 0.18$	5×10^{-4}
Keşif ε	$0.35 \rightarrow 0.03$ (decay 0.999)	frac 0.35, son 0.05
Replay buffer	—	10^5
`learning_starts`	—	5000
Batch boyutu	—	32
`train_freq`	—	4 adım
Hedef ağ güncel.	—	1000 adım
Mimari	tablo $\lvert S\rvert \times 2$	MLP [64, 64]

TABLE IV
SONUÇLAR (SEED ORT.±STD, FULL; YÜKSEK=IYI).

Politika	Tür	Getiri	Std	Cull
qlearning	ajan	**−204**	30	0.72
mdp_value_iteration	referans	−225	42	0.45
dqn	ajan	**−270**	20	0.82
risk_threshold	baseline	−385	53	0.85
keep_all	baseline	−428	34	0.00
random_policy	baseline	−964	56	0.75
cull_all	baseline	−1300	0	1.00

ayırt edilemezdir: aradaki fark, tohum/episode değerlendirme gürültüsü içindedir (eşli t-testi $p \approx 0.37$; bir tohumda VI öndedir). Dolayısıyla VI gerçek tavandır ve Q-Learning onu geçmez, gürültü içinde ona ulaşır. Ayrıca getiri dağılımı sağa çarpıktır (Q-Learning medyan −556, ortalama −204): ajan, `keep_all`'ın sol-kuyruk felaket episode'larını cull ederek beklenen getiriyi (RL'in optimize ettiği ortalama) iyileştirir.

A. Öğrenme Eğrisi (Şekil 2)

Her iki ajanın *eğitim episode getirisi*, tohum ortalamasında istikrarlı biçimde yükselir: Q-Learning ≈ -1000'den ≈ -450'ye, DQN ≈ -1200'den ≈ -400'e ilerler. Tablo ajanı daha hızlı ve oturmuş bir eğri verirken, DQN ilk binlerce adımda daha gürültülüdür; bunun nedeni fonksiyon yaklaşımı ve tekrar arabelleğinin başlangıçta yarattığı değişkenliktir. Gölgeli std bandı, getirinin tek bir şanslı koşunun değil, beş tohum üzerinde sistematik bir öğrenmenin ürünü olduğunu gösterir. Pratik çıkarım, y-ekseninin anlık ödül değil episode getirisi olması sayesinde öğrenmenin açıkça görünür olmasıdır.

B. Test/Değerlendirme Eğrisi (Şekil 3)

Deterministik/açgözlü değerlendirme getirisi eğitimle birlikte iyileşir ve yeşil kesik çizgiyle gösterilen VI optimum referansına yaklaşır ve onunla örtüşür (istatistiksel olarak ayırt edilemez). Değerlendirme eğrisi, keşif kapalı olduğu için eğitim eğrisinden daha az gürültülüdür; bu, eğitim eğrisinin tek başına politika kalitesinin kanıtı sayılamayacağını gösterir. Açgözlü koşu, öğrenilen değer fonksiyonunun fiilî politika kalitesini ölçer; ortam stokastik olduğundan değerlendirme de bir dağılımdır. Sonuç olarak öğrenilen politikalar, görülmemiş episode başlangıçlarında da tutarlı getiri üretmektedir.

C. Kayıp ve Politika Isı Haritası (Şekil 4)

Sol panelde DQN'in TD-kaybı, logaritmik eksende başlangıç değerinden hızla düşerek yakınsar; bu, Q-hedefine doğru kararlı bir optimizasyonun göstergesidir. Tablo yöntemlerinde kayıp bulunmadığından, sağ panelde Q-Learning'in öğrendiği politika bir ısı haritasıyla verilir: risk bandı ve DIM'e göre ortalama cull oranı. Desen iktisadi olarak beklendiği gibidir: yüksek riskli ve ileri laktasyondaki ineklerde cull eğilimi belirgin biçimde artar. Hem optimizasyon dinamiği (kayıp) hem de karar yapısı (ısı haritası) bu yüzden sağlıklı ve yorumlanabilirdir.

D. Hiperparametre Duyarlılığı (Şekil 5)

$\varepsilon_0 \times \alpha$ ızgarası (3×3, tohum başına tekrarlı) en yüksek getiriyi orta düzey keşif ($\varepsilon_0 = 0.35$) ve orta düzey öğrenme oranında ($\alpha = 0.18$) verir. Uç köşeler daha kötüdür: çok az keşif ajanı yeterince farklı durumu görmeden erken sömürüye sıkıştırır, çok fazla keşif ise eğitim bütçesini rastgele aksiyonlarda harcar; aşırı yüksek α ise güncellemeleri gürültüye aşırı duyarlı kılarak yakınsamayı bozar. Bu klasik keşif–sömürü dengesidir. Seçilen varsayılanların tam da bu en iyi hücreye denk gelmesi, konfigürasyonun keyfî değil veriyle gerekçeli olduğunu gösterir.

E. Baseline Karşılaştırması (Şekil 6)

Final açgözlü değerlendirme getirisi, eğitilmiş ajanların (mavi) tüm naif ve heuristik baseline'ları (turuncu) açık ara geçtiğini gösterir; VI optimum (yeşil) tavan referanstır. Naif politikalar arasında `cull_all` en kötüsüdür (−1300, her hayvanı hemen çıkarmak değer yaratmaz), `random` ve `keep_all` da düşüktür. Ajanların gecikmeli ödülü ve stokastik geçişleri hesaba katması, miyop baseline'lara karşı ölçülebilir bir iktisadi üstünlük sağlar. Hata çubukları (±std) bu üstünlüğün tohumlar arasında tutarlı olduğunu doğrular ve böylece çevre seçimini gerekçelendirir.

VII. KAVRAMSAL ANALIZ

Determinizm. Ortam stokastiktir: `keep` için $p(s' \mid s, \text{keep})$ empirik bir dağılımdır (durumların %74'ünde >1 olası s'; `rl_experiment_utils.py:161`). Aynı tohumla aynı yörüngenin elde edilmesi yalnızca tekrarlanabilirliği gösterir, dinamiğin deterministik olduğunu değil; başlangıç *ve* geçiş kuralı stokastiktir, `cull` ise deterministik terminaldir.

On/Off-policy. Q-Learning off-policy'dir: davranış ε-greedy (`rl_core.py:309`), hedef açgözlü max (`:321`). DQN de off-policy'dir ve replay buffer kullanır (`:474`). Her ikisi de *online* (simülatörle etkileşerek) öğrenir; bu, on/off ayrımıyla karıştırılmamalıdır. Gerçek loglu davranış-politikası verisi bulunmadığından CQL/IQL gibi gerçek offline yöntemler kapsam dışıdır.

Markov. Empirik geçiş modeli `state_bucket`→`next` olarak Markov varsayımı altında kurulmuştur; süt trendi

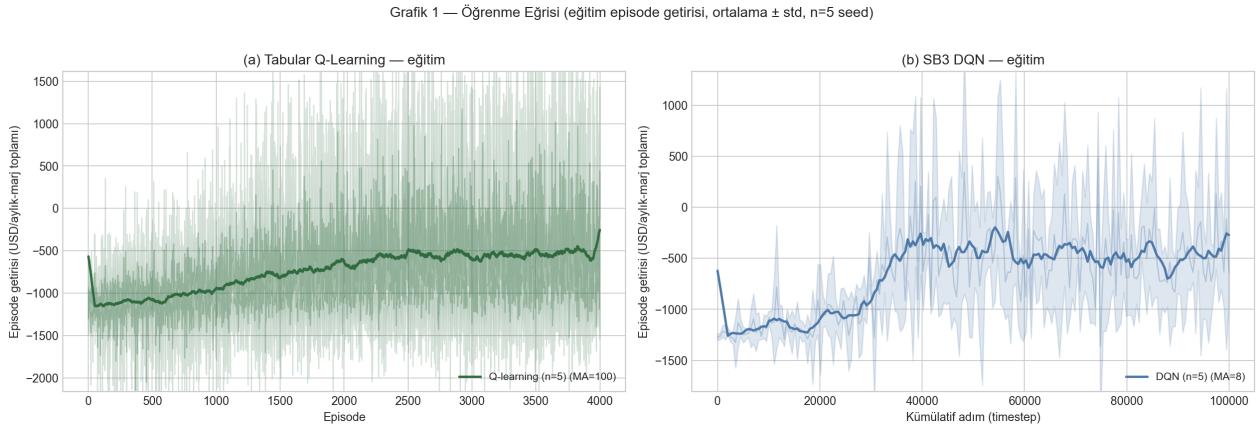


Fig. 2. Öğrenme eğrisi: eğitim episode getirisi (y) – episode/timestep (x); $n=5$ tohum, ortalama±std bandı ve hareketli ortalama.

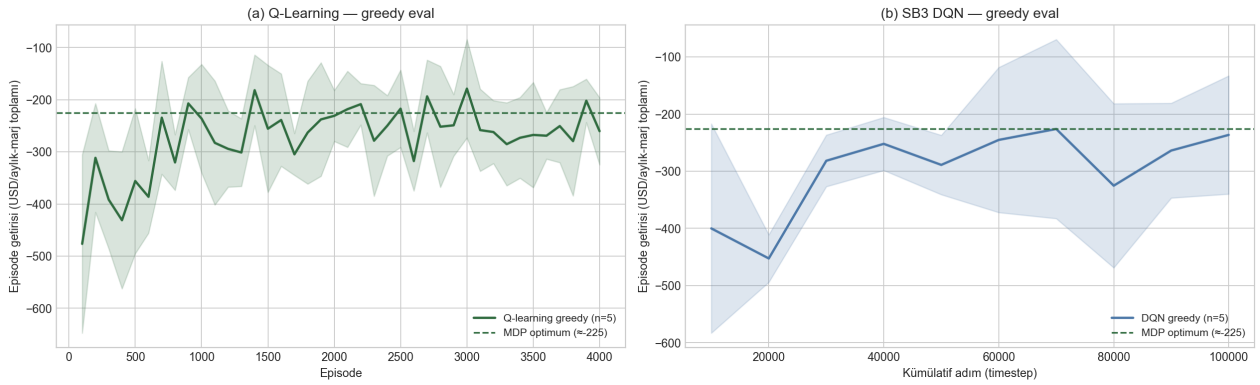


Fig. 3. Değerlendirme eğrisi: deterministik/açgözlü politika; yeşil kesik çizgi VI optimum referansı. $n=5$ tohum, ortalama±std.

ve risk bandı geçmişi özetleyerek bu varsayımı güçlendirir. Ancak ayrıklaştırma bilgi kaybı yarattığından özellik *yaklaşık* Markov'dur; tam gebelik günü veya hastalık şiddeti gibi ince bilgiler durumda yer almaz.

POMDP. Gerçek durum (ineğin tam fizyolojisi) ile gözlem (aylık, ayrık, sensörle sınırlı snapshot) ayrışır; `cull_risk` gerçek bir etiket değil denetimli bir *tahmindir* [8]. Trend ve risk özniteliklerinin eklenmesi (öznitelik mühendisliği), gözlemi Markov'a yaklaştıran ve vanilla DQN'in kısmi gözlemlenebilirlik sınırını hafifleten bir çözümdür; risk skoru bir tür sıkıştırılmış inanç (belief) gibi davranır.

VIII. Sınırlamalar

Süt fiyatı (0.4668) ve bakım maliyeti (8.5337) USDA 2025 kaynaklıdır; replacement, cull, tedavi ve tohumlama maliyetleri prototip varsayımıdır (`reward_baseline_us_2025.csv`, `value_source` sütunu). Politika bu varsayımlara duyarlıdır; senaryo analizi bu duyarlılığı incelemek için mevcuttur. Simülatör empirik bir MDP'dir, üretim politikası değildir. Gerçek loglu aksiyon bulunmadığından offline RL ve sürekli-aksiyon yöntemleri bu fazda uygulanmamıştır.

IX. Sonuç

Ardışık, gecikmeli-ödüllü ve stokastik bir keep/cull ortamı kurularak problemin RL gerektirdiği gösterilmiş; model-free Q-Learning ve DQN ajanları $\geq$ 5 tohum üzerinde tüm baseline'ları geçmiş ve model-tabanlı optimuma istatistiksel olarak eşitlenmiştir (fark anlamlı değildir). Ödül mekanizması kaynak kodla birebir eşleşir, tüm sonuçlar ham loglardan doğrulanabilir ve tek komutla yeniden üretilebilir. Gelecek çalışmada gerçek loglu aksiyonlarla offline RL ve daha zengin durum gösterimleriyle POMDP yaklaşımları değerlendirilebilir.

References

[1] R. S. Sutton ve A. G. Barto, *Reinforcement Learning: An Introduction*, 2. bs. MIT Press, 2018.

[2] C. J. C. H. Watkins ve P. Dayan, "Q-learning," *Machine Learning*, c. 8, ss. 279–292, 1992.

[3] V. Mnih *ve diğ.*, "Human-level control through deep reinforcement learning," *Nature*, c. 518, ss. 529–533, 2015.

[4] M. Towers *ve diğ.*, "Gymnasium," Zenodo, 2023.

[5] A. Raffin *ve diğ.*, "Stable-Baselines3: Reliable reinforcement learning implementations," *JMLR*, c. 22, 2021.

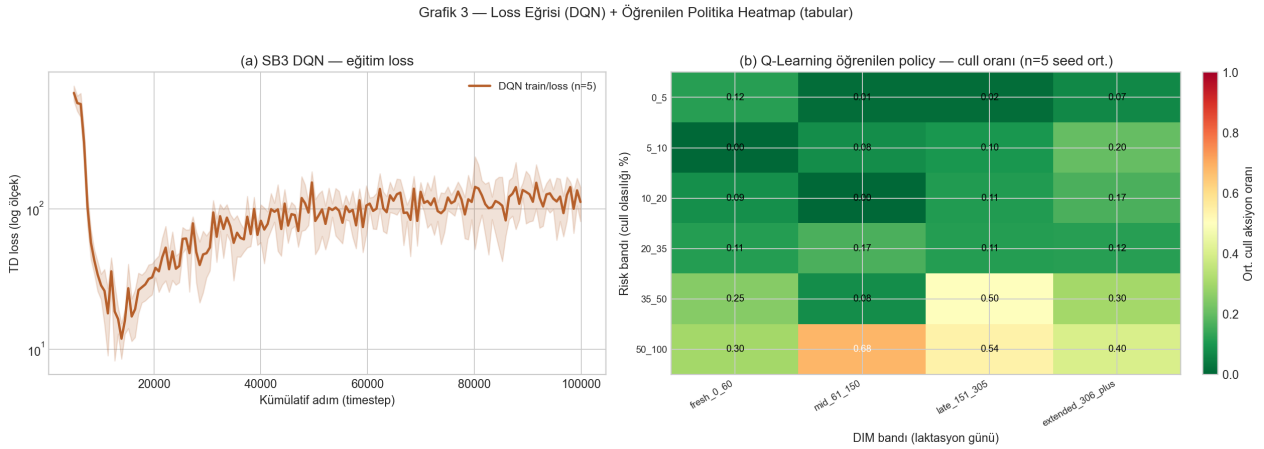


Fig. 4. Sol: DQN eğitim kaybı (log eksen). Sağ: Q-Learning öğrenilen politikanın risk×DIM ısı haritası (ortalama cull oranı, $n=5$).

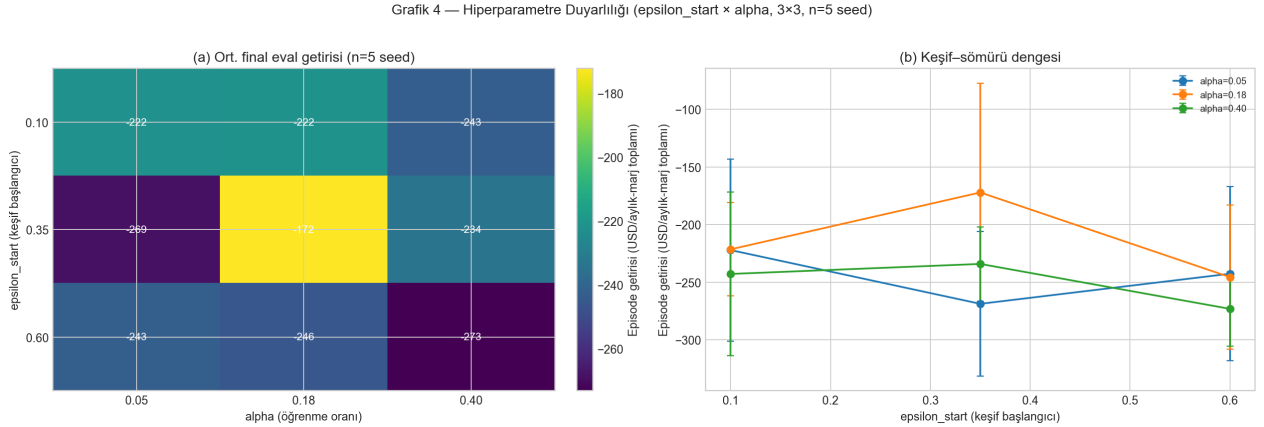


Fig. 5. Hiperparametre duyarlılığı: $\varepsilon_0 \times \alpha$ (3×3), $n=5$ tohum. Sol: ortalama getiri ısı haritası. Sağ: keşif–sömürü eğrileri.

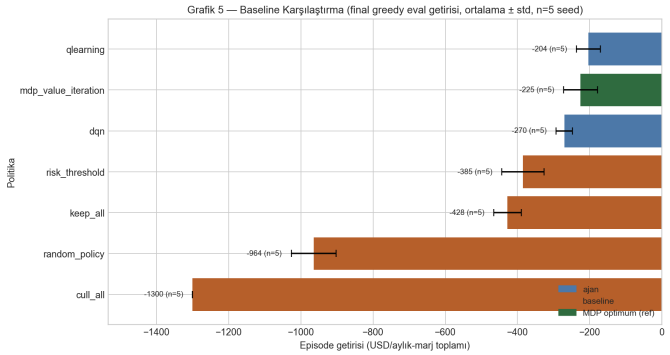


Fig. 6. Baseline karşılaştırması: final açgözlü değerlendirme getirisi (ortalama±std, $n = 5$). Mavi: ajan, turuncu: baseline, yeşil: VI optimum.

[6] A. R. Kristensen, "Optimal replacement and ranking of dairy cows determined by a hierarchic Markov process," *Livestock Production Science*, c. 16, ss. 131–144, 1987.

[7] V. E. Cabrera, "A simple formulation and solution to the replacement problem: A practical tool to assess the economic cow value," *J. Dairy Science*, c. 95, ss. 4683–4698, 2012.

[8] L. P. Kaelbling, M. L. Littman ve A. R. Cassandra, "Planning and acting in partially observable stochastic domains," *Artificial Intelligence*, c. 101, ss. 99–134, 1998.